

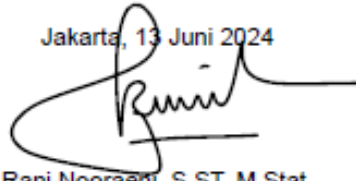
**Surat Persetujuan Makalah dan Buku Skripsi untuk Ujian Skripsi**  
**Prodi D-IV Komputasi Statistik Tahun Akademik 2023/2024**

Saya, selaku dosen pembimbing skripsi dari:

Nama : Anasrul  
NIM : 222011520  
Judul Skripsi : Peningkatan Akurasi Deteksi dan Estimasi Luas Lahan Perkebunan  
Kopi dengan Metode Penajaman Citra (Studi Kasus : Kabupaten  
OKU Selatan, Provinsi Sumatera Selatan)

menyatakan bahwa makalah dan buku skripsi telah diperiksa dan disetujui untuk  
disidangkan.

Jakarta, 13 Juni 2024



Rani Nooraeni, S.ST, M.Stat

**ANALISIS PAN-SHARPENING UNTUK PENINGKATAN**

**AKURASI DETEKSI DAN ESTIMASI LUAS LAHAN**

**PERKEBUNAN KOPI**

**(Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi  
Sumatera Selatan)**

**ANASRUL**

**222011520**

**PROGRAM STUDI : KOMPUTASI STATISIK PROGRAM DIV  
PEMINATAN : SAINS DATA**



**POLITEKNIK STATISTIKA STIS**

**JAKARTA**

**2024**

**ANALISIS PAN-SHARPENING UNTUK PENINGKATAN  
AKURASI DETEKSI DAN ESTIMASI LUAS LAHAN**

**PERKEBUNAN KOPI**

**(Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi  
Sumatera Selatan)**

**SKRIPSI**

**Diajukan sebagai Salah Satu Syarat untuk Memperoleh Sebutan  
Sarjana Terapan Statistika pada Politeknik Statistika STIS**

**Oleh :**

**ANASRUL**

**222011520**



**POLITEKNIK STATISTIKA STIS**

**JAKARTA**

**2024**

**PERNYATAAN**

**Skripsi dengan Judul**

**ANALISIS *PAN-SHARPENING* UNTUK PENINGKATAN**

**AKURASI DETEKSI DAN ESTIMASI LUAS LAHAN**

**PERKEBUNAN KOPI**

**(Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi  
Sumatera Selatan)**

**Oleh:**

**ANASRUL**

**222011520**

adalah benar-benar hasil penelitian sendiri dan bukan hasil plagiat atau hasil karya orang lain. Jika di kemudian hari diketahui ternyata skripsi ini hasil plagiat atau hasil karya orang lain, penulis bersedia skripsi ini dinyatakan tidak sah dan sebutan Sarjana Terapan Statistika dicabut atau dibatalkan.

Jakarta, 3 Juli 2023

  
Anasrul

**ANALISIS *PAN-SHARPENING* UNTUK PENINGKATAN  
AKURASI DETEKSI DAN ESTIMASI LUAS LAHAN  
PERKEBUNAN KOPI**

**(Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi  
Sumatera Selatan)**

Oleh:  
**ANASRUL**  
**222011520**


Tim Penguji

Penguji I



Prof. Setia Prana S.Si., Ph.D.  
NIP 197707222000031002

Penguji II



Ibnu Santoso S.S.T., M.T.  
NIP 198601202008011002

Mengetahui/Menyetujui

Ketua Program Studi Komputasi Statistik  
Program Diploma IV



Ibnu Santoso, S.S.T., M.T.  
NIP 198601202008011002

Pembimbing



Rani Nooraeni S.S.T., M.Stat  
NIP 198306072007012009

© *Hak Cipta milik Politeknik Statistika STIS, Tahun 2022*

***Hak Cipta dilindungi undang-undang***

- *Dilarang mengutip sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini tanpa mencantumkan atau menyebutkan sumbernya.*
  - *Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.*
  - *Pengutipan tidak merugikan kepentingan yang wajar Politeknik Statistika STIS.*
- *Dilarang mengumpulkan dan memperbanyak sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini dalam bentuk apapun tanpa seizin Politeknik Statistika STIS.*

## **PRAKATA**

Puji syukur penulis ucapkan kepada Allah SWT, karena atas izin-Nya penulis dapat menyelesaikan skripsi yang berjudul “Peningkatan Akurasi Deteksi dan Estimasi Luas Lahan Perkebunan Kopi dengan Metode Penajaman Citra (Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi Sumatera Selatan)”. Penulis juga mengucapkan terima kasih kepada:

1. Ibu Dr. Erni Tri Astuti M.Math., selaku Direktur Politeknik Statistika STIS;
2. Bapak Ibnu Santoso, SST., M.T., selaku Ketua Program Studi D-IV Komputasi Statistik Politeknik Statistika STIS;
3. Ibu Rani Nooraeni, SST., M.Stat., selaku dosen pembimbing yang telah bersedia meluangkan waktu dalam membimbing penyusunan skripsi ini;
4. Bapak Prof. Setia Pramana S.Si., Ph.D. dan Bapak Ibnu Santoso, SST., M.T., selaku dosen penguji atas koreksi dan saran yang disampaikan;
5. Ibu, Ayah, serta kakak saya yang telah memberikan banyak dukungan secara moril;
6. Teman-teman saya dan semua pihak yang telah memberikan dukungan dalam penulisan skripsi ini.

Penulis menyadari skripsi ini masih jauh dari kesempurnaan. Oleh karena itu, saran dan kritik yang membangun sangat penulis harapkan demi perbaikan skripsi ini. Semoga skripsi ini dapat bermanfaat bagi semua pihak.

Jakarta, xx Juli 2022

**Anasrul**

## ABSTRAK

“Analisis Pan-Sharpening untuk Peningkatan Akurasi Deteksi dan Estimasi Luas Lahan Perkebunan Kopi (Studi Kasus: Kabupaten Ogan Komering Ulu Selatan, Provinsi Sumatera Selatan)”.

vii+69

PENGUNAAN teknologi *remote sensing* dalam pemantauan perkebunan kopi menjadi semakin penting mengingat peran vital kopi dalam perekonomian sebagai produk ekspor yang meningkatkan pendapatan negara. Indonesia, sebagai produsen kopi terbesar ketiga di dunia, memiliki perkebunan kopi seluas 1,25 juta ha dengan produktivitas rata-rata 832 kg/ha. Namun, data luas areal perkebunan kopi hanya tersedia dari Survei Perusahaan Perkebunan (SKB) yang memiliki keterbatasan. Oleh karena itu, dibutuhkan alternatif lain seperti *remote sensing*. Meskipun demikian, tantangan masih ada, terutama terkait resolusi citra satelit yang rendah yang menghambat pemantauan akurat dan efisien terhadap lahan kopi. Penelitian ini bertujuan untuk meningkatkan akurasi analisis lahan perkebunan kopi di Kabupaten OKU Selatan, Provinsi Sumatera Selatan, dengan penggunaan metode *pan-sharpening* yang terdiri dari IHS, *Brovey*, dan *Gram-Schmidt* serta dibantu dengan indeks komposit. Pengambilan data sampel citra satelit dari Landsat-8 dilakukan pada 1800 titik yang terbagi menjadi enam kelas. Penciri lahan perkebunan kopi memiliki nilai NDVI, EVI, dan ARVI yang cenderung lebih rendah tetapi lebih tinggi pada nilai NDBI dan NDWI daripada kelas perkebunan non-kopi dan hutan. Penelitian ini juga membandingkan data hasil metode *pan-sharpening* dengan menggunakan metode *machine learning* dan *deep learning* untuk mendapatkan model pengklasifikasian terbaik. Hasil penelitian menunjukkan metode *machine learning* model SVM memberikan hasil terbaik dengan nilai *F1-score* sebesar 84,17 persen.

Kata kunci: Perkebunan Kopi, *pan-sharpening*, *machine learning*, *deep learning*, *remote sensing*.



## DAFTAR ISI

<b>PRAKATA.....</b>	<b>i</b>
<b>ABSTRAK .....</b>	<b>ii</b>
<b>DAFTAR ISI.....</b>	<b>iii</b>
<b>DAFTAR TABEL .....</b>	<b>v</b>
<b>DAFTAR GAMBAR.....</b>	<b>vi</b>
<b>DAFTAR LAMPIRAN.....</b>	<b>vii</b>
<b>BAB I PENDAHULUAN.....</b>	<b>1</b>
1.1 Latar Belakang .....	1
1.2 Identifikasi Masalah.....	3
1.3 Rumusan Masalah.....	5
1.4 Tujuan Penelitian .....	5
1.5 Batas Penulisan.....	6
1.6 Sistematika Penulisan.....	6
<b>BAB II KAJIAN PUSTAKA.....</b>	<b>8</b>
2.1 Landasan Teori.....	8
Perkebunan Kopi.....	8
Survei Perusahaan Perkebunan Komoditas Kopi.....	9
<i>Remote Sensing</i> .....	11
Landsat 8 Collection 2 Tier 1 TOA Reflectance.....	12
<i>Pan-Sharpening</i> .....	13
<i>Intensity Hue Saturation (IHS)</i> .....	15
<i>Brovey transformation</i> .....	16
<i>Gram-Schmidt</i> .....	17
<i>Machine Learning</i> .....	18
<i>Support Vector Machines (SVM)</i> .....	18
<i>Random Forest</i> .....	20
<i>Extreme Gradient Boosting (XGBoost)</i> .....	20
<i>Deep Learning</i> .....	21
<i>Multi-Layer Perceptron (MLP)</i> .....	22
<i>Convolutional Neural Network</i> .....	22

<i>Grid Search CV</i> .....	23
<i>Stratified K-Fold (SKF) Cross Validation</i> .....	24
Evaluasi Model.....	24
2.2 Penelitian Terkait .....	25
2.3 Kerangka Pikir .....	26
<b>BAB III METODOLOGI</b> .....	28
3.1 Area Studi Penelitian .....	28
3.2 Metode Pengumpulan Data .....	29
Data Citra .....	29
Data Sampel .....	30
Pemberian Label.....	32
Proses <i>Pan-sharpening</i> .....	33
Pengumpulan Fitur.....	34
3.3 Metode Analisis.....	36
<b>BAB IV HASIL DAN PEMBAHASAN</b> .....	40
4.1 Identifikasi Fitur Terbaik Penciri Citra Lahan Perkebunan Kopi...40	
4.2 Pembentukan Model Klasifikasi Terbaik Dalam Mendeteksi Lahan Perkebunan Kopi.....	45
4.3 Mengestimasi Luas Lahan Perkebunan Kopi Menggunakan Model Terbaik .....	48
<b>BAB V</b> .....	53
<b>KESIMPULAN DAN SARAN</b> .....	53
5.1 Kesimpulan .....	53
5.2 Saran.....	54
<b>DAFTAR PUSTAKA</b> .....	55
<b>LAMPIRAN</b> .....	60
<b>RIWAYAT HIDUP</b> .....	72

## DAFTAR TABEL

No. Tabel	Judul Tabel	Halaman
1	Luas lahan perkebunan kopi di Provinsi Sumatera Selatan (Ha) tahun 2021-2022.....	2
2	Karakteristik band pada citra satelit Landsat-8.....	13
3	Minimum jumlah sampel pada setiap kelas .....	31
4	Jumlah sampel setiap kelas target .....	31
5	Pita multispektral citra satelit Landsat-8.....	35
6	Formula indeks komposit.....	36
7	Hasil perhitungan GVF fitur pada citra satelit .....	40
8	Rentang kelompok level pada citra satelit .....	41
9	Perbandingan performa model <i>machine learning</i> menggunakan <i>stratified 5-fold cross validation</i> .....	45
10	Perbandingan performa model <i>machine learning</i> terbaik dengan <i>deep learning</i> menggunakan <i>stratified 5-fold cross validation</i> .....	47
11	Perbandingan hasil estimasi luas perkebunan kopi dengan data tabel dinamis berdasarkan kecamatan di Kabupaten OKU Selatan tahun 2022.....	49

## DAFTAR GAMBAR

No. Gambar	Judul Gambar	Halaman
1	Diagram alir <i>Pan-sharpening</i> .....	14
2	Ilustrasi <i>Support Vector Machine</i> .....	19
3	Kerangka pikir.....	27
4	Peta batas wilayah Kabupaten OKU Selatan .....	29
5	Tangkapan citra satelit Landsat-8 Kabupaten OKU Selatan.....	30
6	Citra tutupan lahan: (a) Perkebunan Kopi; (b) Hutan menggunakan <i>Google Earth</i> .....	32
7	Perbandingan citra tutupan lahan pada Landsat-8 (kiri) dan <i>Google Earth</i> (kanan) .....	33
8	Tangkapan masing-masing citra asli dan hasil <i>Pan-sharpening</i> .....	34
9	Alur <i>workflow</i> penelitian.....	39
10	Distribusi fitur pada citra Landsat-8 .....	42
11	Distribusi fitur pada citra Landsat-8 hasil <i>Pan-sharpening IHS</i> .....	42
12	Distribusi fitur pada citra Landsat-8 hasil <i>Pan-sharpening Brovey</i> .....	43
13	Distribusi fitur pada citra Landsat-8 hasil <i>Pan-sharpening Gram- Schmidt</i> .....	43
14	Hasil klasifikasi model SVM pada citra satelit Landsat-8 data IHS.....	52

## DAFTAR LAMPIRAN

No. Lampiran	Judul Lampiran	Halaman
1	<i>Hyperparameter tuning SVM</i> .....	59
2	<i>Hyperparameter tuning Random Forest</i> .....	59
3	<i>Hyperparameter tuning XGBoost</i> .....	59
4	<i>5-fold SVM</i> .....	59
5	<i>5-fold Random Forest</i> .....	61
6	<i>5-fold XGBoost</i> .....	62
7	Arsitektur CNN-1D .....	63
8	<i>5-fold MLP</i> .....	64
9	<i>5-fold CNN-1D</i> .....	65
10	Peta estimasi luas lahan perkebunan kopi .....	66

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Kopi merupakan komoditas ekspor yang memiliki nilai ekonomi yang relatif tinggi di pasar dunia. Kopi sendiri merupakan salah satu komoditas pangan yang paling banyak diperdagangkan di dunia. Menurut *Statista Research Department*, pasar global untuk kedai kopi diperkirakan mencapai \$165,7 miliar pada tahun 2022. Selain itu, kopi juga merupakan salah satu komoditas terpenting dalam perdagangan internasional dan memiliki peran signifikan dalam mempengaruhi perekonomian global. Indonesia menjadi salah satu negara pengekspor utama komoditi kopi dunia. Tahun 2022, Indonesia menjadi negara pengekspor kopi urutan ketiga setelah Brazil dan Vietnam. Indonesia tercatat memproduksi kopi sebanyak 11,85 juta kantong. Sementara Brazil memproduksi kopi sebanyak 62,6 juta kantong kopi. kemudian, Vietnam yang memproduksi kopi 29,75 juta kantong kopi (USDA,2022b).

Provinsi Sumatera menjadi penyumbang terbesar produksi kopi dengan total nilai produksi sebesar 212,4 ribu ton atau 26,72 dari total produksi kopi nasional pada tahun 2022. Produksi kopi di Sumatera selatan naik 0,33 persen dari tahun sebelumnya(BPS, 2022b). Mengenai jumlah produksi sangat erat kaitannya dengan luas lahan perkebunan karena bisa diperoleh melalui perhitungan luas lahan perkebunan. Luas lahan perkebunan kopi di sumatera selatan pada tahun 2022 sebesar 267.867 Ha. Kabupaten OKU Selatan menjadi Kabupaten dengan luas lahan perkebunan kopi terluas dibandingkan dengan kabupaten atau kota di Provinsi

Sumatera Selatan, yaitu mencapai 89.823,5 Ha atau 33,2 persen dari total luas perkebunan kopi provinsi. Terjadi penurunan lahan perkebunan kopi sebesar 0,63 persen di Kabupaten Oku Selatan sejak tahun 2021.

Tabel 1. Luas lahan perkebunan kopi di Provinsi Sumatera Selatan (Ha) tahun 2021-2022

<b>Kabupaten/Kota</b>	<b>Tahun</b>	
	<b>2021</b>	<b>2022</b>
(1)	(2)	(3)
<b>Sumatera Selatan</b>	<b>266174</b>	<b>267867</b>
Ogan Komering Ulu	22009	22068
Ogan Komering Ilir	814	814
Muara Enim	23102	23102
Lahat	54441	54441
Musi Rawas	3848	3835
Musi Banyuasin	3	3
Banyuasin	-	2032
Ogan Komering Ulu Selatan	89823,5	89260
Ogan Komering Ulu Timur	-	483
Ogan Ilir	0	0
Empat Lawang	62132	62138
Pali	0	0
Musi Rawas Utara	300	280
Palembang	0	0
Prabumulih	0	0
Pagar Alam	8327	8151
Lubuk Linggau	1374	1260

Pengumpulan data mengenai lahan perkebunan kopi merupakan hal yang sangat penting demi memastikan akurasi dan ketepatan data yang diperoleh. Saat ini, di Indonesia, pendekatan konvensional digunakan untuk mengumpulkan data mengenai perkebunan kopi. Identifikasi lahan perkebunan kopi dilakukan melalui

Survei Perusahaan Perkebunan (SKB) yang dilakukan oleh Badan Pusat Statistik (BPS). Metode yang digunakan mencakup pencacah lengkap self-enumeration atau imput mandiri dan Analisis Perkebunan melalui SEAAP oleh pemilik perkebunan, serta pengisian data melalui SKB online untuk yang belum melakukan pencacahan mandiri.. Selain itu, data juga diperoleh dari Direktorat Jenderal Perkebunan, Kementerian Pertanian. Data mengenai lahan perkebunan kopi yang terkumpul mencakup informasi tentang luas lahan, jumlah produksi, produktivitas, status tanaman, serta status pengusahaan. Dalam kerangka Survei Perusahaan Perkebunan (SKB) yang dilaksanakan oleh Badan Pusat Statistik (BPS), data dikumpulkan untuk perkebunan dengan status pengusahaan Perkebunan Besar Negara (PBN) dan Perkebunan Besar Swasta (PBS). Sementara itu, Direktorat Jenderal Perkebunan mengumpulkan data mengenai Perkebunan Rakyat (PR)(BPS,2022b).

Metode pengumpulan data pada SKB Komoditas Kopi yang saat ini digunakan memiliki beberapa batasan yang signifikan. Pada prosesnya, diperlukan banyak tenaga atau petugas cacah sehingga membutuhkan biaya pelaksanaan yang besar, diperlukan periode waktu yang lama sehingga mendorong adanya lag update selama satu tahun dalam publikasinya, rentan terhadap adanya kondisi tidak terduga seperti fenomena atau bencana alam, dan terdapat wilayah perkebunan kopi yang sulit terjangkau (remote area) sehingga terlewat / tidak tercacah.

## **1.2 Identifikasi Masalah**

Adanya keterbatasan pada metode saat ini telah membuka peluang untuk mengeksplorasi alternatif metode baru dalam pendataan perkebunan kopi di Indonesia. Teknologi penginderaan jauh atau remote sensing muncul sebagai solusi yang sangat potensial. Kelebihannya termasuk ketersediaan citra satelit "tidak



berbayar", pembaruan citra satelit sesuai keadaan lapangan setiap 10 hingga 16 hari, kekebalan terhadap kondisi fenomena atau bencana alam, dan kemampuannya untuk mencakup area perkebunan kopi yang sulit dijangkau, termasuk daerah terpencil. Teknologi ini membuka peluang atau perspektif baru dalam efisiensi dan akurasi pendataan, memberikan manfaat yang signifikan untuk pengelolaan perkebunan kopi di Indonesia.

Teknologi remote sensing mengalami perkembangan yang semakin pesat karena saat ini data penginderaan jauh (citra satelit) semakin mudah didapat (Yao, dkk., 2017), sehingga pemanfaatan teknologi remote sensing telah banyak digunakan oleh para peneliti di dunia untuk mengidentifikasi suatu lahan perkebunan, salah satunya yaitu perkebunan kopi. Misalnya T. Anggun, dkk mengimplementasikan metode Random Forest dalam memetakan lahan perkebunan kopi menggunakan citra satelit GeoEye-1, Sentinel 2, dan DEMNAS 2. (Anggun, dkk., 2020). C. Alberto, dkk mengimplementasikan metode Support Vector Machine (SVM), Neural Network (NN), dan Linear Regression (LR) dalam memperkirakan hasil panen tanaman kopi menggunakan citra multispektral dan algoritma pembelajaran mesin menggunakan citra satelit Sentinel-2 (Alberto, dkk, 2022)

Perkembangan teknologi penginderaan jauh satelit saat ini mengarah kepada peningkatan resolusi spasial (*high resolution*) dan peningkatan saluran spektral (*hyperspectral*). Satelit Landsat-8 OLI mempunyai saluran multispektral, dan saluran pankromatik dengan resolusi spasial lebih baik. Saluran multispektral memberikan informasi warna, dan saluran pankromatik mempunyai informasi tekstur yang lebih menonjol. Dengan menggabungkan kedua informasi tersebut yaitu informasi warna dan informasi tekstur diharapkan mampu memberikan

informasi yang lebih detail dan lebih akurat mengenai suatu obyek(Wandayani, 2007).

Perkembangan teknologi penginderaan jauh memberikan beberapa metode untuk melakukan penggabungan citra yang biasa disebut dengan image fusion (fusi citra) dan *pan-sharpening*. Metode-metode *pan-sharpening* tersebut menghasilkan citra dengan nilai spektral yang berbeda beda, sesuai dengan algoritmanya. Dalam penelitian kali ini akan menganalisis beberapa metode *pan-sharpening* tersebut. Untuk melihat metode manakah yang memiliki ketelitian lebih baik, metode-metode tersebut akan dibandingkan dengan cara melakukan uji akurasi antara hasil klasifikasi citra terhadap data sebenarnya di lapangan. Penggunaan citra satelit Landsat-8 OLI perlu dikaji. Penelitian ini diarahkan pada kajian penggunaan data Landsat-8 OLI pada lahan kopi, khususnya yang berhubungan dengan estimasi luas perkebunan kopi.

### **1.3 Rumusan Masalah**

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah yang perlu untuk diidentifikasi dalam meningkatkan akurasi mendeteksi lahan perkebunan kopi dengan pendekatan penajaman citra .

1. Bagaimana proses *pan-sharpening* dapat digunakan untuk mendeteksi lahan perkebunan kopi?
2. Bagaimana model klasifikasi terbaik dapat dibentuk untuk mendeteksi lahan perkebunan kopi?
3. Bagaimana tingkat ketelitian metode *pan-sharpening* dapat dianalisis dan bagaimana luas lahan perkebunan kopi dapat diestimasi menggunakan model terbaik yang didapat?

#### **1.4 Tujuan Penelitian**

Berdasarkan rumusan masalah, dalam melakukan peningkatan akurasi deteksi lahan perkebunan kopi dengan pendekatan penajaman citra, terdapat tiga sub tujuan yang perlu dicapai

1. Mengetahui efek dari berbagai metode pan-sharpening untuk mendeteksi lahan perkebunan kopi
2. Membentuk model klasifikasi terbaik dalam mendeteksi lahan perkebunan kopi.
3. Menganalisis tingkat ketelitian metode pan-sharpening dan mengestimasi luas lahan perkebunan kopi menggunakan model terbaik yang didapat.

#### **1.5 Batasan Penelitian**

Dalam penelitian ini, terdapat beberapa keterbatasan data resmi dalam membagi wilayah berdasarkan tutupan lahan menurut titik koordinat perkebunan kopi di Indonesia. Ketersediaan data resmi tidak lengkap dimana hanya beberapa titik koordinat perkebunan kopi yang terdata. Selain itu, proses penentuan label kelas tutupan lahan dalam proses identifikasi model klasifikasi lahan perkebunan kopi terbatas dan lebih berfokus melalui validasi virtual atau secara tidak langsung. Peneliti memanfaatkan citra satelit beresolusi tinggi yang disediakan oleh Google Earth dan Google Street View pada Google Maps serta data pendukung dari Geoportal wilayah penelitian untuk memastikan keabsahan label yang digunakan serta mengonfirmasi dengan penyedia data yaitu BPS kabupaten OKU Selatan . Hal

ini dilakukan karena adanya keterbatasan sumber daya, pemeriksaan langsung di lapangan belum dapat dilakukan.

## **1.6 Sistematika Penulisan**

Penulisan skripsi terdiri dari lima bab yang merujuk pada pedoman penulisan skripsi di Politeknik Statistika STIS (Polstat STIS). Bab I adalah Pendahuluan yang menjelaskan latar belakang, rumusan masalah, tujuan penelitian, batasan penelitian, dan sistematika penulisan.

Bab II adalah Kajian Pustaka, berupa landasan teori yang menjadi dasar penelitian, penelitian terkait, serta kerangka pikir penelitian. Bab III adalah Metodologi, berupa wilayah studi, metode pengumpulan data, pengumpulan fitur, dan metode analisis yang digunakan pada penelitian ini. Bab IV adalah Hasil dan Pembahasan, berupa hasil analisis deskriptif mengenai fitur penciri lahan perkebunan kopi dan model klasifikasi terbaik dari machine learning atau deep learning, serta estimasi luas lahan perkebunan kopi berdasarkan model terbaik sesuai dengan kerangka pikir penelitian.

Bab terakhir yaitu Bab V adalah Kesimpulan dan Saran, berupa kesimpulan dari hasil dan pembahasan, serta rekomendasi berupa saran dari penulis bagi para penerima manfaat penelitian ini. Selain itu, sumber-sumber lain berupa buku, jurnal, hasil penelitian, dan bahan referensi lainnya yang menjadi rujukan dalam penelitian ini disajikan dalam daftar pustaka.

## **BAB II**

### **KAJIAN PUSTAKA**

#### **2.1 Landasan Teoris**

##### **Perkebunan Kopi**

Tanaman kopi diyakini berasal dari hutan tropis di wilayah Afrika. Kopi Arabika berasal dari daerah pegunungan tinggi di Ethiopia Barat dan wilayah utara Kenya, sedangkan kopi Robusta berasal dari Pantai Gading dan Republik Afrika Tengah. Hal ini menunjukkan bahwa tanaman kopi memiliki kemampuan adaptasi yang tinggi terhadap lingkungan tumbuhnya (Siswoputranto, 1992).

Ada dua jenis utama kopi yang ditanam di Indonesia:

- Kopi Arabika: Jenis kopi yang paling banyak dikembangkan di dunia dan di Indonesia. Ditanam pada dataran tinggi dengan ketinggian sekitar 1350-1850 meter di atas permukaan laut. Kopi Arabika memiliki aroma dan rasa yang kuat.
- Kopi Robusta: Dikenal sebagai *Coffea canephora*. Rasanya lebih pahit, sedikit asam, dan mengandung lebih banyak kafein. Kopi Robusta dapat tumbuh di dataran rendah hingga ketinggian 1000 meter di atas permukaan laut.

Faktor-faktor seperti ketinggian lahan, suhu udara, dan curah hujan memengaruhi pertumbuhan dan produksi tanaman kopi. Kopi memiliki potensi yang besar sebagai komoditas ekspor dan sumber devisa bagi negara-negara penghasil. Beberapa faktor yang menunjukkan potensi ini meliputi:

- **Permintaan Global:** Minuman kopi merupakan salah satu minuman paling populer di seluruh dunia. Permintaan terus meningkat, terutama di negara-negara berkembang.
- **Nilai Tambah:** Kopi memiliki nilai tambah yang tinggi melalui proses pengolahan, seperti pemanggangan biji kopi, pembuatan kopi bubuk, dan pembuatan minuman kopi siap saji.
- **Ekosistem:** Perkebunan kopi dapat berkontribusi pada keberagaman hayati dan keseimbangan ekosistem. Tanaman kopi memberikan tempat bagi burung dan serangga, serta memperkaya tanah dengan nutrisi.
- **Pengembangan Varietas Unggul:** Pengembangan varietas kopi yang tahan terhadap hama dan penyakit serta menghasilkan biji berkualitas tinggi dapat meningkatkan produktivitas dan kualitas hasil panen.
- **Pengelolaan Berkelanjutan:** Praktik perkebunan kopi yang berkelanjutan, termasuk penggunaan pupuk organik dan pengelolaan air yang bijaksana, dapat memastikan keberlanjutan produksi kopi.

### **Survei Perusahaan Perkebunan Komoditas Kopi**

Survei perusahaan perkebunan adalah suatu kegiatan pengumpulan data yang dilakukan untuk mengetahui kondisi perusahaan perkebunan. perkebunan merupakan usaha pertanian yang menjadi suatu kegiatan ekonomi dengan mengusahakan tanaman peladangan yang banyak dikelola secara individu (Syechalad, 2009). Survei perusahaan perkebunan dilakukan secara berkala baik Triwulanan maupun tahunan. Data yang dikumpulkan mencakup luas areal tanam dan produksi setiap komoditas perkebunan. Luas areal tanam mencakup luas tanaman belum menghasilkan (TBM), tanaman menghasilkan (TM), tanaman tidak menghasilkan (TTM), dan tanaman rusak (TR). Dari informasi luas areal tanaman

kemudian dapat diperoleh informasi produktivitas yang merupakan hasil pembagian produksi komoditas perkebunan terhadap luas areal TM.

Dalam prakteknya, terdapat proses sinkronisasi data untuk menghasilkan satu angka statistik perkebunan. Sinkronisasi melibatkan lembaga dan institusi yang berwenang menghasilkan data, yakni BPS, Dinas Perindustrian, Dinas Perdagangan, asosiasi dan perusahaan perkebunan. Pada saat sinkronisasi dilakukan serangkaian analisis untuk menjelaskan penyebab perubahan (naik dan turun) pada data, membandingkan data antar waktu, dan uji petik secara sampling ke lapangan.

Survei perusahaan perkebunan di Indonesia memiliki peran penting dalam mengumpulkan data dan informasi terkait sektor perkebunan. Beberapa tujuan survei ini meliputi:

- **Pemantauan Produksi dan Produktivitas** : Mengumpulkan data tentang produksi dan produktivitas tanaman perkebunan untuk mengukur kinerja sektor dan mengidentifikasi potensi peningkatan.
- **Analisis Ekonomi**: Data dari survei digunakan untuk menganalisis aspek ekonomi perkebunan, termasuk nilai produksi, biaya produksi, dan pendapatan petani. Informasi ini membantu dalam perencanaan kebijakan dan pengambilan keputusan.
- **Pengawasan dan Pengendalian** : Survei membantu mengawasi kegiatan perusahaan perkebunan, termasuk penggunaan lahan, pengelolaan sumber daya alam, dan kepatuhan terhadap regulasi. Ini memastikan praktik yang berkelanjutan dan sesuai dengan peraturan.
- **Penyusunan Kebijakan**: Data dari survei digunakan oleh pemerintah dan lembaga terkait untuk merumuskan kebijakan yang mendukung pengembangan

sektor perkebunan, seperti kebijakan investasi, peningkatan produktivitas, dan perlindungan lingkungan.

- **Penelitian dan Pengembangan:** Informasi dari survei membantu peneliti dan akademisi mengidentifikasi tren, masalah, dan peluang di sektor perkebunan. Data ini dapat digunakan untuk penelitian lebih lanjut dan pengembangan teknologi.

Dengan demikian, survei perusahaan perkebunan berperan penting dalam menginformasikan kebijakan, mengawasi praktik, dan memastikan keberlanjutan sektor perkebunan di Indonesia.

### ***Remote Sensing***

*Remote sensing* (penginderaan jauh) adalah ilmu dan seni memperoleh informasi mengenai objek, daerah, atau fenomena melalui analisis data yang diperoleh dengan alat tanpa kontak langsung dengan objek, daerah, atau fenomena tersebut (Lillesand, Kiefer, dan Chipman, 2015). Secara umum, penginderaan jauh digunakan untuk mengidentifikasi rupa bumi melalui analisis radiasi elektromagnetik yang dipantulkan atau dipancarkan oleh permukaan bumi. Setiap objek di permukaan bumi memantulkan atau menghamburkan sebagian energi elektromagnetik yang mengenainya, dan juga memancarkan radiasi sesuai dengan suhu dan emisivitasnya. Secara khusus, satelit digunakan sebagai platform yang membawa sensor-sensor pencitraan untuk melaksanakan tugas ini, sehingga disebut sebagai satelit penginderaan jauh.

Deteksi dan pemisahan objek atau fitur permukaan bumi melibatkan pendeteksian dan perekaman energi radiasi yang dipantulkan atau dipancarkan oleh objek atau material di permukaan. Berbagai objek akan memancarkan nilai dan jenis energi



yang berbeda dalam spektrum elektromagnetik. Sistem penginderaan jauh yang menggunakan sensor pada satelit atau pesawat terbang bisa berupa sistem aktif atau pasif. Sistem sensor aktif memanfaatkan energi yang dipancarkan sendiri oleh satelit atau pesawat, sementara sistem sensor pasif bergantung pada pencahayaan dari matahari atau emisi dari objek untuk pengamatannya. Data citra optik diperoleh dari sistem sensor pasif pada satelit, sedangkan data kontur (bentuk permukaan bumi) dan citra radar diperoleh dari sistem sensor aktif..

### **Landsat 8**

Teknologi penginderaan jauh menggunakan satelit pertama kali dipelopori oleh NASA. Landsat 8 adalah kelanjutan dari misi Landsat yang pertama kali diluncurkan sebagai satelit pengamat bumi sejak tahun 1972 (Purwanto, 2016). Pada tahun 2013, NASA meluncurkan satelit *Landsat Data Continuity Mission* (LDCM), yang mulai menyediakan produk citra *open access* sejak 30 Mei 2013. Setelah itu, NASA menyerahkan satelit tersebut kepada USGS untuk pengelolaan data. Data citra kemudian dikelola oleh *Earth Resources Observation and Science* (EROS) *Centre*. Landsat 8 beroperasi pada ketinggian 705 km dari permukaan bumi dengan area pemindaian seluas 170 km x 183 km. Landsat 8 menangkap rentang spektrum gelombang elektromagnetik yang lebih panjang, sehingga dianggap sangat cocok untuk penelitian identifikasi sebaran tanaman kopi karena citranya yang sangat teliti.

Satelit *Landsat 8* memiliki sensor *Onboard Operational Land Imager* (OLI) dan *Thermal Infrared Sensor* (TIRS) dengan total 11 kanal, terdiri dari 9 kanal (band 1-9) pada OLI dan 2 kanal (band 10 dan band 11) pada TIRS. Sebagian besar kanal ini memiliki spesifikasi masing-masing..

Tabel 2. Karakteristik band pada citra satelit Landsat-8

Nama	Resolusi	Panjang Gelombang	Deskripsi
B1	30 meter	0,43 - 0,45 $\mu\text{m}$	Coastal aerosol
B2	30 meter	0,45 - 0,51 $\mu\text{m}$	Blue
B3	30 meter	0,53 - 0,59 $\mu\text{m}$	Green
B4	30 meter	0,64 - 0,67 $\mu\text{m}$	Red
B5	30 meter	0,85 - 0,88 $\mu\text{m}$	Near infrared
B6	30 meter	1,57 - 1,65 $\mu\text{m}$	Shortwave infrared 1
B7	30 meter	2,11 - 2,29 $\mu\text{m}$	Shortwave infrared 2
B8	15 meter	0,50 - 0,68 $\mu\text{m}$	Band 8 Panchromatic
B9	30 meter	1,36 - 1,38 $\mu\text{m}$	Cirrus
B10	30 meter	10,60 - 11,19 $\mu\text{m}$	Thermal infrared 1, resampled from 100m to 30m
B11	30 meter	11,50 - 12,51 $\mu\text{m}$	Thermal infrared 2, resampled from 100m to 30m


### ***Pan-Sharpening***

*Pan-Sharpening* atau Penajaman merupakan suatu metode transformasi berbasis spasial, dengan kata lain yaitu merubah resolusi spektral citra satelit menggunakan metode tertentu sehingga menghasilkan kenampakan obyek yang ideal untuk interpretasi secara visual. Resolusi spektral adalah *bandwidth*

elektromagnetik dari sinyal yang ditangkap oleh sensor yang menghasilkan gambar tertentu. Semakin sempit *bandwidth* spektral, semakin tinggi resolusi spektral. Jika platform menangkap gambar dengan beberapa pita spektral, biasanya 4-7, mereka disebut sebagai data multispektral (MS), sedangkan jika jumlah pita spektral diukur dalam ratusan atau ribuan, mereka disebut sebagai *hyperspectral* (HS). Bersama-sama dengan gambar MS atau HS, satelit biasanya menyediakan gambar pankromatik (PAN). Ini adalah gambar yang mengandung data pantulan yang mewakili berbagai panjang gelombang dari inframerah yang terlihat hingga termal, yaitu, ia mengintegrasikan informasi kromatik, oleh karena itu, namanya "pan" berwarna. Gambar pan dari pita yang terlihat menangkap kombinasi data merah, hijau, dan biru menjadi satu ukuran pantulan (Amro, 2011).

Penajaman citra dengan menggunakan data citra pankromatik (*image Pansharpening*) dengan mengombinasikan data citra multispektral (warna) yang mempunyai resolusi rendah dengan citra pankromatik (hitam-putih atau tingkat keabuan) yang mempunyai resolusi tinggi (Vrabel, 1996). *Pan-sharpening* sangat penting untuk berbagai aplikasi, seperti meningkatkan klasifikasi gambar, untuk mendeteksi perubahan menggunakan data temporal, untuk meningkatkan kualitas geometrik, segmentasi gambar, dan untuk meningkatkan visibilitas objek tertentu yang tidak muncul pada data tertentu. Dengan demikian, teknik *pan-sharpening* meningkatkan resolusi spasial sekaligus menjaga informasi spektral, memberikan yang terbaik dari dua resolusi: resolusi spektral dan resolusi spasial (Vijayaraj, 2004).

Diagram alir berikut menunjukkan langkah-langkah untuk penggabungan gambar. Setelah proses penggabungan selesai, algoritma segmentasi dapat diterapkan.



Gambar 1. Diagram alir *Pan-sharpening*

### ***Intensity Hue Saturation (IHS)***

Metode IHS menerangkan bahwa saluran terpisah menguraikan sifat warna tertentu, yaitu Intensitas (I), Hue (H), dan Saturation (S). Ruang warna spesifik ini sering dipilih karena sistem kognitif visual manusia cenderung menjadikan ketiga unsur tersebut sebagai sumbu persepsi ortogonal. Namun, di penginderaan jauh, band-band citra biasanya ditetapkan ke saluran RGB untuk menghasilkan komposit warna palsu sebagai tujuan tampilan saja. Komponen intensity merefleksikan informasi total kecerahan dari suatu warna tampilan. Hue menunjukkan rata-rata panjang gelombang dari warna tampilan, sedangkan saturation mencerminkan kedalaman warna relatif terhadap abu-abu (Vincent, 1997).

Metode IHS didasarkan pada peralihan dari model warna RGB (merah-hijau-biru) ke model warna IHS (intensitas-hue-saturasi). Komponen intensitas, yang merupakan gambar panchromatic sintetis (S), digunakan untuk menggabungkan data gambar pankromatik (PAN) dan gambar multispektral (MS) sesuai dengan kerangka kerja penggabungan, yang disebut generalized IHS (GIHS), di mana komponen intensitas disediakan oleh:

$$S = \frac{1}{n} \sum_{k=1}^n MS_k$$

di mana  $n$  mewakili jumlah band multispektral dan  $MS_k$  adalah gambar multispektral ke- $k$ .

Gambar multispektral yang di pan-sharpened dihasilkan menggunakan rumus berikut:

$$MS'_k = MS_k + PAN - S$$

di mana  $MS'_k$  adalah gambar di pan-sharpened ke- $k$ .

Dengan menganalisis respons spektral dari dataset asli, bobot dapat diperkenalkan untuk menghitung  $S$ . Ini disebut IHS fast (IHSF), di mana  $S$  diperoleh sebagai berikut :

$$S = \frac{1}{\sum_{k=1}^n w_k} \times \sum_{k=1}^n MS_k$$

di mana  $w_k$  adalah bobot dari band multispektral ke- $k$ .

### ***Brovey transformation***

Metode Transformasi *Brovey* (BT) merupakan metode yang paling sering digunakan untuk memadukan 2 macam citra yang berbeda resolusi spasial dan spektral. Metode *Brovey* dalam proses pengolahannya menggunakan rumus otomatis, yaitu ketiga saluran spektral RGB (*Red, Green, Blue*) akan di *resample* ke dalam ukuran piksel gambar pankromatik (PAN), baik menggunakan *nearest neighbor*, *bi-linear*, ataupun *cubic convolution*. Hasilnya akan meningkatkan suatu citra yang kontras, sehingga jika dilihat dari sisi spektral warna akan menghasilkan citra yang lebih terang (Wandayani, 2007).

Metode Transformasi *Bovey* dikembangkan untuk meningkatkan kontras secara visual pada ujung rendah dan tinggi histogram gambar dan dengan demikian mengubah *radiometric scene* asli. Gambar *dipan-sharpened* BT dapat dihitung sebagai berikut :

$$MS'_k = \frac{MS_k}{S} \times PAN$$

Pada tahap ini, ada dua parameter masukan yang dipertimbangkan yaitu gambar pankromatik (PAN) dan gambar multispektral (MS). Untuk memudahkan proses perbandingan, pemilihan gambar MS yang cocok akan dilakukan berdasarkan tingkat peningkatan pada gambar yang digabungkan. Tingkat peningkatan dalam penelitian ini dievaluasi secara visual. Ini didefinisikan sebagai jumlah wilayah di mana tingkat intensitas telah diubah menjadi nol dalam suatu gambar. Berbagai masukan gambar MS akan menghasilkan tingkat peningkatan yang berbeda pada gambar yang terbentuk.

### ***Gram-Schmidt***

Menurut ESRI (2012), teknik *image fusion* metode *Gram-Schmidt* dilandaskan pada algoritma umum untuk proses ortogonalisasi pada data vektor. Diterapkan pada data vektor (x, y, z) yang tidak ortogonal menjadi data vektor yang ortogonal. Dalam prosesnya setiap band pada data citra baik itu pankrometrik maupun multispektral dijadikan menjadi satu dimensi vektor, dengan x dimensi vektor adalah x piksel.

Langkah pertama yang dilakukan pada metode *Gram-Schmidt* adalah dengan membuat data citra pankrometrik dengan menghitung nilai rata-rata bobot band pada data citra multispektral. Hasil nilai band tersebut kemudian dihubungkan

menggunakan algoritma ortogonal metode *Gram-Schmidt* dan menganggap setiap band sebagai satu vektor multidimensi. Band pankromatik resolusi rendah secara bersamaan digunakan menjadi vektor pertama, yang tidak dilakukan rotasi dan transformasi. Band pankromatik resolusi rendah tersebut kemudian digantikan oleh band pankromatik resolusi tinggi dan semua band ditransformasi kembali menjadi resolusi tinggi (Laben dan Brower, 2000). Band-band yang digabungkan diperoleh sebagai berikut:

$$MS'_k = MS_k + g_k(PAN - S)$$

di mana  $g_k$  adalah *gain*, diperoleh dari:

$$g_k = \frac{cov(MS_k, S)}{var(S)}$$

di mana  $cov(MS_k, S)$  adalah kovariansi antara gambar multispektral ke-k awal dan gambar sintetis;  $var(S)$  adalah varians  $S$

### ***Machine Learning***

*Machine learning* adalah serangkaian teknik yang membantu dalam menangani dan memprediksi data dalam jumlah besar dengan menggunakan algoritma pembelajaran untuk mempresentasikan data tersebut (Danukusumo, 2017). Istilah *machine learning* pertama kali didefinisikan oleh Arthur Samuel pada tahun 1959. Menurut Arthur Samuel, *machine learning* adalah suatu bidang ilmu komputer yang memberikan kemampuan kepada komputer untuk belajar dan memahami sesuatu tanpa harus diprogram secara eksplisit..


Menurut (Mohri et al., 2012), *machine learning* dapat didefinisikan sebagai metode komputasi yang menggunakan pengalaman untuk meningkatkan kinerja atau membuat prediksi yang akurat. Dalam konteks ini, pengalaman merujuk pada

informasi sebelumnya yang tersedia dan dapat digunakan sebagai data pembelajaran.

### ***Support Vector Machines (SVM)***

*Support Vector Machine* (SVM) pertama kali diperkenalkan oleh Vapnik (1992) di *Annual Workshop on Computational Learning Theory* sebagai sebuah metode *machine learning* yang bertujuan untuk menemukan *hyperplane* terbaik yang dapat memisahkan dua kelas dari data input. Pada awalnya, SVM merupakan metode klasifikasi linier, namun kemudian dikembangkan untuk diterapkan pada masalah *nonlinear* dengan mengimplementasikan konsep *trick kernel* pada data yang berdimensi tinggi

Berdasarkan penelitian Wahyudi & Kusumawardana (2021), metode SVM merupakan metode terbaik untuk mengklasifikasikan dataset ulasan. SVM. merupakan metode yang tepat untuk memecahkan masalah untuk data yang berdimensi tinggi dengan data yang terbatas karena SVM akan meminimalkan error dari data latih.



Gambar 2. Ilustrasi *Support Vector Machine*

Konsep SVM adalah menemukan *hyperplane* terbaik untuk memisahkan kelas -1 dan +1. *Hyperplane* terbaik ditentukan dengan mengukur *margin*, yaitu



jarak antara *hyperplane* dengan pola terdekat dari masing-masing kelas. Pola terdekat ini disebut *support vector* (Nugroho, 2008).

Kebanyakan data pada dunia nyata bersifat nonlinear (Naufal et al., 2015). Untuk menangani data nonlinear dengan SVM, digunakan konsep yang disebut *kernel trick* (Nugroho, 2008). *Kernel trick* mempermudah pembelajaran SVM karena memungkinkan penentuan *support vector* hanya dengan mengetahui fungsi kernel yang digunakan (Naufal et al., 2015). Beberapa fungsi kernel yang umum digunakan meliputi fungsi linear, fungsi polinomial, *Radial Basis Function* (RBF), dan *sigmoid* (Nugroho, 2008).

### ***Random Forest***

random forest adalah algoritma pembelajaran ensemble untuk tahapan data mining dengan tugas klasifikasi dan regresi (Ho, 1995). Random forest menggunakan teknik bagging untuk membangun ensemble decision tree. Pada penelitiannya, Breiman menyebutkan beberapa kelebihan dari random forest diantaranya dapat menghasilkan hasil akhir klasifikasi yang baik dan error yang lebih rendah, mampu mengatasi jumlah data yang cukup banyak secara lebih baik dan adalah salah satu algoritma yang efektif dalam permasalahan missing data (Breiman, 2001). Nilai akurasi pada sebuah classifier tunggal dapat ditingkatkan dengan menggunakan metode ensemble, caranya dengan menggunakan lebih dari satu classifier dari algoritma yang sama lalu mengkombinasikannya dengan cara voting untuk mendapatkan hasil dugaan klasifikasi akhir sebagai hasil akhir dari sebuah proses klasifikasi (Wezel dan Potharst, 2007).

Semakin banyak pohon yang digunakan, maka nilai akurasi akan semakin baik. Untuk melakukan prediksi pada sampel baru pada random forest dilakukan

dengan cara memasukkan sampel ke dalam pohon keputusan yang sudah terbentuk untuk ditentukan kelas dari sampel tersebut. Langkah ini dilakukan secara berulang kali terhadap keseluruhan pohon keputusan yang terdapat pada random forest. Hasil voting dari beberapa pohon keputusan yang terbentuk merupakan batasan yang dijadikan sebagai penentuan kelas pada proses klasifikasi. Pohon keputusan dengan vote yang paling banyak merupakan pemenang dari penentuan kelas klasifikasi (Ho, 1995).

### ***Extreme Gradient Boosting (XGBoost)***

*Extreme Gradient Boosting* atau XGBoost dikembangkan oleh (Chen & Guestrin, 2016). XGBoost merupakan salah satu metode *boosting*, di mana setiap *decision tree* dalam model dibangun secara berurutan dan pembangunan setiap pohon bergantung pada pohon sebelumnya. Pohon pertama dalam XGBoost biasanya lemah dalam melakukan klasifikasi, dengan inisialisasi probabilitas yang ditentukan oleh peneliti. Selanjutnya, bobot pada setiap pohon yang dibangun diperbarui secara iteratif, menghasilkan kumpulan pohon klasifikasi yang kuat.

### ***Deep Learning***

*Deep Learning* merupakan salah satu bidang dari *machine learning* yang menggunakan jaringan syaraf tiruan untuk menangani permasalahan dengan dataset yang besar. Teknik *deep learning* memberikan arsitektur yang sangat kuat untuk *supervised learning*. Dengan menambahkan lebih banyak lapisan, model pembelajaran dapat mewakili data citra berlabel dengan lebih baik. Pada *machine learning*, terdapat teknik untuk ekstraksi fitur dari data pelatihan dan algoritma pembelajaran khusus untuk mengklasifikasi citra atau mengenali suara. Namun,

metode ini masih memiliki beberapa kekurangan, terutama dalam hal kecepatan dan akurasi..

Aplikasi konsep jaringan syaraf tiruan yang dalam (dengan banyak lapisan) telah menghasilkan kemajuan signifikan dalam algoritma *machine learning* yang ada, memungkinkan komputer untuk belajar dengan kecepatan, akurasi, dan skala yang besar. Prinsip ini terus berkembang hingga *deep learning* semakin umum digunakan dalam komunitas riset dan industri untuk memecahkan berbagai masalah data besar seperti *Computer vision*, *Speech recognition*, dan *Natural Language Processing*.

*Feature Engineering* merupakan salah satu fitur utama dari *deep learning* yang memungkinkan ekstraksi pola yang berguna dari data, memudahkan model untuk membedakan kelas. Meskipun demikian, *Feature Engineering* juga merupakan teknik yang sulit untuk dipelajari dan dikuasai karena berbagai jenis data memerlukan pendekatan teknik yang berbeda. Model yang kompleks sering kali membutuhkan waktu pelatihan yang lama, sehingga penggunaan GPU telah menjadi umum di dunia *deep learning* (Danukusumo, 2017).

### ***Multi Layer Perceptron***

Jaringan saraf tiruan lapis banyak atau disebut *multilayer perceptron* merupakan pengembangan lebih lanjut dari perceptron lapis tunggal. Pembelajaran menggunakan algoritma delta yang disebut *error backpropagation training algorithm*, *argument* dimasukkan diumpamakan secara arah maju sedangkan proses pembelajaran selain melakukan perambatan arah maju juga memanfaatkan perambatan arah balik. Apabila hasil tidak sesuai dengan target maka bobot

diperbaharui selama proses siklus pembelajaran hingga tercapai nilai kesalahan minimum yang diharapkan atau keluaran sama dengan target. (Muis, 2006)

### ***Convolutional Neural Network***

*Convolutional Neural Network* (CNN) merupakan pengembangan dari *Multilayer Perceptron* (MLP) yang dirancang khusus untuk mengolah data dua dimensi dalam bentuk citra. CNN termasuk dalam jenis *Deep Neural Network* karena memiliki kedalaman jaringan yang tinggi dan banyak diaplikasikan pada data citra. Meskipun klasifikasi citra dapat dilakukan menggunakan MLP, namun metode MLP kurang sesuai karena tidak mempertahankan informasi spasial dari data citra dan menganggap setiap piksel sebagai fitur yang independen, yang dapat menghasilkan hasil yang kurang baik. Penelitian awal yang mendasari penemuan CNN ini dilakukan oleh Hubel dan Wiesel pada tahun 1968 mengenai virtual cortex pada indera penglihatan kucing.

Secara teknis, CNN adalah arsitektur yang dapat dilatih dan terdiri dari beberapa tahap. Setiap tahap memiliki masukan (*input*) dan keluaran (*output*) yang terdiri dari beberapa *array* yang dikenal sebagai *feature map*. Setiap tahap terdiri dari tiga layer: layer konvolusi, layer fungsi aktivasi, dan layer *pooling*.

### ***Grid Search CV***

*Grid Search* adalah metode yang digunakan untuk mencari parameter yang tepat untuk meningkatkan performa model dengan mencoba seluruh kombinasi hyperparameter yang diberikan (Müller dan Guido, 2016). Grid Search juga menyediakan fitur untuk melakukan *cross validation*. Proses ini bertujuan untuk mengevaluasi performa model secara lebih umum karena adanya ketergantungan performa dengan pembagian data. Jumlah fold yang ingin dilakukan dapat

diberikan pada parameter *cross validation* (cv) ketika melakukan inisiasi *Grid Search* CV dari *sklearn*. Apabila value tidak diberikan, maka secara default akan menjalankan *5-fold cross validation*.

### **Stratified K-Fold (SKF) Cross Validation**

*Cross-validation* adalah metode statistik digunakan untuk melakukan proses penilaian pada teknik analisis/algoritma data yang dipilih serta proses membandingkan kinerja terhadap masing-masing algoritma/teknik yang dipilih. Pada *cross-validation*, data dibagi ke dalam dua bagian yaitu data training dan data *testing* (Refaeilzadeh dkk., 2009; Yadav dan Sukhla, 2016). Baik set data pelatihan dan data *testing* harus bersifat *cross-over* dalam putaran secara berturut-turut sedemikian rupa sehingga setiap blok data memiliki peluang untuk divalidasi. Bentuk dasar dari *cross-validation* adalah *k-fold cross-validation* (Refaeilzadeh dkk., 2009). Proses yang dilakukan pada *k-fold cross validation* dimulai dari membagi data terlebih dahulu menjadi k sama dengan ukuran segmen atau bagian. Pelatihan model dilakukan pada bagian k-1 dan sisa bagian untuk dilakukan pengujian. Prosesnya akan dilakukan secara berulang kali sambil mengubah bagian tes satu persatu sampai pada pengujian telah dilakukan pada semua bagian (Yadav dan Sukhla, 2016).

### **Evaluasi Model**

Evaluasi bertujuan untuk menilai performa suatu sistem klasifikasi dengan mengetahui akurasi dari model yang dibuat (Fitriyah, 2020). Terdapat empat kriteria evaluasi yang dipertimbangkan yaitu precision, *recall*, accuracy, dan f1- score (Attal et al., 2015).

- Precision

Precision adalah ukuran ketepatan antara hasil prediksi suatu model. Berikut adalah rumus precision yang dapat dilihat pada persamaan (1).

$$Precision = \frac{TP}{FP+TP} \quad (1)$$

- **Accuration**

Accuration adalah perbandingan antara informasi yang diprediksi dengan benar oleh model dengan keseluruhan informasi. Berikut adalah rumus accuration yang dapat dilihat pada persamaan (2).

$$Accuration = \frac{TN+TP}{FN+FP+TN+TP} \quad (2)$$

- **Recall**

*Recall* tingkat ketepatan informasi yang sama dengan informasi yang sudah pernah dipanggil sebelumnya. Berikut adalah rumus *recall* yang dapat dilihat pada persamaan (3).

$$Recall = \frac{TP}{FN+TP} \quad (3)$$

- **F1-Score**

F1-score adalah perbandinga rata-rata presisi dan *recall* yang dibobotkan. Berikut adalah rumus f1-score yang dapat dilihat pada persamaan (4).

$$F1 - Score = \frac{2 K (Recall K Precision)}{Recall+Precision} \quad (4)$$

## 2.2 Penelitian Terkait

Penelitian yang dilakukan oleh J. Jagannathan dan C. Divya (2020) bertujuan untuk memprediksi dan mengklasifikasikan perubahan penggunaan lahan dan tutupan lahan menggunakan jaringan saraf konvolusi dalam pembelajaran

mendalam metode Convolutional Neural Network (CNN) pada citra satelit Sentinel-2. Penelitian ini dilakukan dengan menggunakan teknologi jaringan saraf konvolusi (CNN) untuk memproses citra satelit Sentinel-2 dan memprediksi perubahan penggunaan lahan dan tutupan lahan. Hasil penelitian menunjukkan bahwa teknologi CNN dapat digunakan untuk memprediksi perubahan penggunaan lahan dan tutupan lahan dengan akurasi yang tinggi<sup>1</sup>.

Penelitian yang dilakukan oleh H. Dibs, H. Ali Hasab, A. S. Mahmoud, dan N. Al-Ansari (2021) menemukan metode penyempurnaan estimasi penggunaan dan tutupan lahan (LULC) dengan menggunakan citra jarak jauh menggunakan tiga pendekatan fusi pan-sharpening untuk menggabungkan citra pankromatik dengan resolusi spasial tinggi dengan citra multispektral dengan resolusi spasial rendah pada citra satelit Landsat-8 OLI1. Penelitian ini bertujuan untuk meningkatkan akurasi estimasi penggunaan dan tutupan lahan (LULC) dengan menggunakan teknologi fusi pan-sharpening pada citra satelit Landsat-8 OLI. Hasil penelitian menunjukkan bahwa teknologi fusi pan-sharpening dapat meningkatkan akurasi estimasi penggunaan dan tutupan lahan (LULC) pada citra satelit Landsat-8 OLI1.

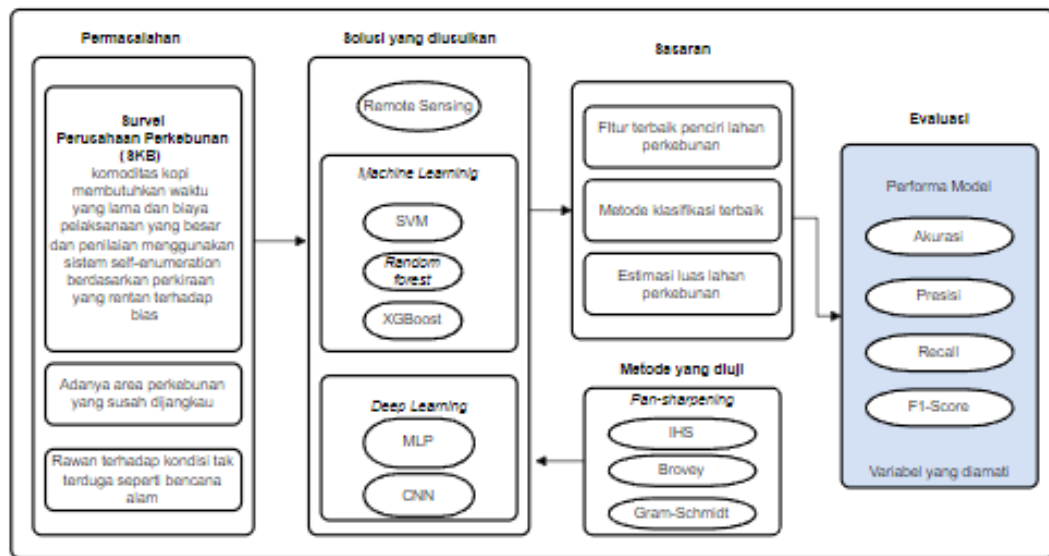
Penelitian yang dilakukan oleh Damayanti dan A. M. Liyanton (2022) bertujuan untuk mengidentifikasi dan memetakan lahan perkebunan kopi dengan memanfaatkan citra satelit Landsat-8 pada platform Google Earth Engine (GEE) menggunakan model Support vector machine (SVM) dan Random Forest<sup>1</sup>. Penelitian ini dilakukan dengan menggunakan teknologi SVM dan Random Forest untuk memproses citra satelit Landsat-8 dan mengidentifikasi lahan perkebunan kopi. Hasil penelitian menunjukkan bahwa teknologi SVM dan Random Forest dapat digunakan untuk mengidentifikasi dan memetakan lahan perkebunan kopi dengan akurasi yang tinggi

## 2.3 Kerangka Pikir

Penelitian ini diawali dengan adanya keterbatasan pada metode pengumpulan data pada Survei Perusahaan Perkebunan (SKB) komoditas kopi oleh Badan Pusat Statistik yang membutuhkan banyak tenaga, waktu, dan biaya yang besar, sulitnya menjangkau area perkebunan kopi, tidak dapat mengantisipasi kondisi yang tak terduga, dan self-enumeration berdasarkan perkiraan pemilik lahan perkebunan kopi. Fokus penelitian ini untuk mengimplementasikan remote sensing dengan memanfaatkan teknik pan-sharpening'(penggabungan citra) untuk menghasilkan citra baru dengan resolusi tinggi tanpa harus meningkatkan *resolving power* suatu citra.

Teknik penggabungan citra juga merupakan suatu bukti bahwa semakin berkembangnya teknologi penginderaan jauh. Namun, keberadaanya belum dimanfaatkan secara luas oleh peneliti, khususnya dalam penelitian untuk mendeteksi lahan perkebunan kopi sehingga memperoleh fitur dan model klasifikasi terbaik dengan membandingkan penggunaan machine learning dengan deep learning serta melakukan estimasi luas lahan perkebunan kopi dari model klasifikasi terbaik. Kerangka pikir menggambarkan jalannya penelitian mulai dari permasalahan, solusi yang diusulkan, sasaran penelitian, dan indikator evaluasi. Kerangka pikir pada penelitian ini mengacu pada buku Thesis Projects: a Guide for Students in Computer Science and Information Systems oleh Berndtsson, Hansson, Olsson, dan Lundell (2007).






Gambar 3. Kerangka pikir

## BAB III

### METODOLOGI

#### 3.1 Area Studi Penelitian

Provinsi Sumatera Selatan merupakan provinsi penghasil produksi kopi terbesar di Indonesia. Berdasarkan data BPS, pada tahun 2022 tercatat produksi kopi sebesar 201.4 ribu ton atau 26 persen dari total produksi kopi nasional. Sementara itu, pada tahun 2022 produksi kopi tercatat sebesar 212.4 ribu ton atau 26,72 persen dari total produksi kopi nasional (BPS, 2022b). Kabupaten OKU Selatan menjadi Kabupaten dengan luas lahan perkebunan kopi terluas dibandingkan dengan kabupaten atau kota di Provinsi Sumatera Selatan, yaitu mencapai 89.823,5 Ha atau 33,2 persen dari total luas perkebunan kopi provinsi (BPS, 2022a). Oleh karena itu, Kabupaten OKU Selatan dipilih sebagai *Region of Interest* (ROI) atau studi lokasi.




Gambar 4. Peta batas wilayah Kabupaten OKU Selatan

### 3.2 Metode Pengumpulan Data

#### Data Citra

Data citra diperoleh dari Satelit Landsat 8 Collection 2 Tier 1 TOA Reflectance dengan menggunakan Google Earth Engine (GEE). GEE merupakan platform cloud computing atau komputasi awan yang memiliki akses pada data citra dari berbagai satelit yang selalu diperbarui dan menyediakan gambar untuk analisis geospasial serta dapat langsung dilakukan preprocessing. Landsat-8 memiliki resolusi spasial hingga 30 meter dengan resolusi temporal 16 hari (Yusof, Shafri, dan Shahrarum, 2021).

Pada Google Earth Engine data citra dilakukan filter periode rentang waktu 2021-2022 dan dilakukan cloud filtering atau koreksi awan sehingga didapatkan citra siap olah. Dari hasil pengamatan terpilih citra terbaik pada rentang bulan april sampai September tahun 2022 dengan persentase awan dibawah 20 persen yang cukup banyak . Langkah berikutnya dilakukan penggabungan gambar citra dengan metode penghilangan awan menjadi satu dengan batasan ROI. Gambar 5 menunjukkan citra Landsat-8 dari hasil preprocessing pada GEE..



Gambar 5. Tangkapan citra satelit Landsat-8 Kabupaten OKU Selatan

## Data Sampel

Pengambilan titik sampel dibagi menjadi enam kelas target yang terdiri dari kelas air, perkebunan kopi, perkebunan non-kopi, hutan, bangunan, dan tanah. Sebanyak 1.800 sampel diambil dan setiap kelasnya memiliki ukuran yang sama yaitu 300 sampel yang mana setiap sampel berupa grid dengan ukuran 10×10 meter. Hal bertujuan untuk menghindari data imbalance, yaitu kondisi salah satu kelas target atau lebih yang ada terdapat suatu himpunan memiliki jumlah yang cukup timpang. Titik sampel diambil pada citra satelit Landsat-8 dan proses pengambilan sampel dilakukan secara manual. Langkah pertama melakukan geotagging objek yang diamati. Kemudian didapatkan piksel hasil geotagging yang mewakili satu titik sampel dan satu kelas target. Satu ukuran piksel bergantung pada citra satelit yang digunakan, pada citra Landsat-8 satu pikselnya berukuran 30x30 meter. Berdasarkan penelitian yang dilakukan Haub, Kleinewillinghöfer, Garcia Millan (EFTAS), dan Di Gregorio (FAO) (2015) *pada Protocol For Land Cover Validation oleh Stimulating Innovation for Global Monitoring Agriculture (SIGMA)*, dalam penentuan jumlah sampel menganut rule of thumb untuk menentukan jumlah sampel minimum pada setiap kelas ditunjukkan pada tabel 3.

Tabel 3. Minimum jumlah sampel pada setiap kelas

Kelas tutupan lahan dan luas lokasi uji	Minimum jumlah sampel setiap kelas
(1)	(2)
<12 kelas dan <1 juta hektar ( $\approx 4000 \text{ km}^2$ )	50
>12 kelas atau >1 juta hektar ( $\approx 4000 \text{ km}^2$ )	75–100

Pada penelitian ini, jumlah kelas yang digunakan sebanyak enam dan luas lokasi uji lebih dari satu juta hektar, sehingga memerlukan setidaknya pada setiap kelas 75 sampai 100 sampel. Titik sampel yang diambil setiap kelas sebesar 300, sehingga sudah melebihi batas minimum pengambilan sampel. Oleh karena itu, dapat dikatakan telah memenuhi syarat jumlah minimum sampel tiap kelas. Tabel 4 menunjukkan jumlah sampel setiap kelas target.

Tabel 4. Jumlah sampel setiap kelas target

Kelas	Nama Kelas	Titik Sampel
(1)	(2)	(3)
1	Air	300
2	Perkebunan Kopi	300
3	Perkebunan Non-kopi	300
4	Hutan	300
5	Bangunan	300
6	Tanah	300
	Total	1800


### Pemberian Label

Pelabelan dibantu menggunakan alat bantu citra satelit milik Google Earth, informasi lokasi sampel dari Google Earth Engine (GEE), tangkapan kamera Google Street View, informasi perkebunan yang terdaftar di Google Maps dan data pendukung Geoportal Kabupaten OKU Selatan. Hal ini disebabkan karena usi Banyu Sils belum tersedianya publikasi data administratif resmi perkebunan kopi pada setiap titik-titik koordinat di Indonesia. Penelitian sebelumnya seperti yang dilakukan Nguyen, Doan, Tomppo, dan McRoberts (2020) dan Nurmasari dan Wijayanto (2021), melakukan proses validasi dengan memanfaatkan citra beresolusi tinggi dari Google Earth. Perlu diketahui bahwa proses pengambilan titik sampel merupakan tahapan dengan tingkat kesulitan yang paling tinggi, mengingat

sulitnya membedakan citra perkebunan kopi dengan hutan. Pada gambar 8, citra perkebunan kopi dan hutan terlihat sangat mirip dan tidak memiliki pola tanam atau keteraturan yang baik, sehingga diperlukan ketelitian yang lebih dalam memilih titik sampel. Proses validasi dilakukan dengan mengambil informasi koordinat longitude dan latitude dari titik sampel. Kemudian menggunakan Google Earth untuk menuju lokasi dan dipastikan kembali dengan Google Street View. Gambar 9 menunjukkan perbandingan antara tangkapan citra satelit Landsat 8 dengan citra resolusi tinggi dari Google Earth.



Gambar 6. Citra tutupan lahan: (a) Perkebunan Kopi; (b) Hutan menggunakan *google Earth*



Gambar 7. Perbandingan citra tutupan lahan pada Landsat-8 (kiri) dan Google Earth (kanan)


## Proses Pan-sharpening

Pan-sharpening dilakukan untuk meningkatkan dan mempertajam resolusi spasial citra guna memperoleh informasi yang lebih banyak daripada citra yang tidak terfusi. Hal ini sangat diperlukan untuk meningkatkan resolusi spasial dari band-band multispektral maupun hyperspektral menjadi resolusi spasial pada band pankromatik. Penajaman citra pada umumnya hanya digunakan untuk tujuan meningkatkan kualitas visual citra karena keterbatasan lebar band pankromatik, yang menyebabkan band-band di luar panjang gelombang tampak secara teori memiliki nilai spektral yang tidak sesuai lagi dengan nilai aslinya. Dalam penelitian ini, tiga metode pan-sharpening yang digunakan adalah IHS (*Intensity-Hue-Saturation*), *Brovey*, dan *Gram-Schmidt*, yang masing-masing dipilih karena alasan spesifik. Metode IHS dipilih karena kemampuannya menggabungkan informasi warna dari citra multispektral dengan detail spasial dari citra pankromatik, serta mempertahankan kualitas warna yang baik, cocok untuk analisis vegetasi dan pemetaan lahan (Carper, Lillesand, dan Kiefer, 1990). Metode *Brovey* dipilih karena kesederhanaannya dan kemampuannya dalam mempertajam citra tanpa menghilangkan informasi spektral, sering digunakan dalam pemetaan geologi dan identifikasi fitur urban (Chavez, Sides, dan Anderson, 1991). Metode *Gram-Schmidt* dipilih karena transformasi matematisnya yang efektif dalam meningkatkan resolusi spasial tanpa mengorbankan informasi spektral, sangat berguna dalam studi perubahan lingkungan dan pemantauan wilayah (Aiazzi dan Selva, 2007). Ketiga metode ini dipilih karena keunggulannya dalam mempertahankan integritas spektral dan meningkatkan kualitas visual citra hasil pan-sharpening.

Metode Intensity Hue Saturation (IHS) memecah warna menjadi intensity (I), hue (H), dan saturation (S), yang sesuai dengan pemahaman manusia terhadap warna. Metode Transformasi *Brovey* (BT) menggabungkan citra dengan resolusi berbeda, meningkatkan kontras dan kecerahan citra untuk memberikan hasil yang lebih tajam dan detail. Sementara Metode Gram-Schmidt, atau modulasi intensitas berbasis filter penghalusan (SFIM), melibatkan simulasi dan transformasi untuk

meningkatkan ketajaman citra, menghasilkan citra yang lebih jelas dan detail, sesuai dengan kebutuhan analisis yang lebih mendalam[.

Untuk mengamati kenampakan visual hasil dari pan-sharpening, penelitian ini mengambil beberapa sampel untuk perbedaan kenampakan visual antara citra landsat-8, pan-sharpening metode IHS, *Brovey*, dan Gram- Schimdt.



Gambar 8. Tangkapan masing-masing citra asli dan hasil *Pan-sharpening*

Secara visual, citra hasil *Brovey* memiliki ketajaman spasial yang tinggi, tetapi informasi warnanya berbeda dari citra multispektral awal karena metode *Brovey* hanya menggunakan rasio dari 3 band spektral. Di sisi lain, metode *Gram Schmidt* menghasilkan gambar yang lebih jelas dan tajam, meskipun warna hijau sedikit menurun. Pada metode IHS gambar dihasilkan hampir menyerupai warna aslinya tapi ketajaman spasial tidak sebaik metode *Brovey*. Pemilihan metode yang cocok harus disesuaikan dengan tujuan analisis citra, seperti pengamatan spektral atau pengamatan tepian objek.

### **Pengumpulan Fitur**



Koleksi fitur terdiri dari beberapa pita multispektral dan indeks komposit sebagai variabel prediktor. Pita multispektral adalah spektrum atau gelombang elektromagnetik dipancarkan dari citra satelit dengan panjang gelombang tertentu. Hanya tiga gelombang elektromagnetik yang dapat terlihat oleh mata manusia, yaitu merah (*red*), hijau (*green*), dan biru (*blue*) atau RGB. Sementara itu, gelombang lainnya tidak dapat terlihat dengan mata manusia, misalnya *Near-Infrared* (NIR) dan *Short Wave Infrared* (SWIR). Objek amatan akan menyerap spektrum dan nilai masing-masing gelombang akan diproses dan dihitung.

Tabel 5. Pita multispektral citra satelit Landsat-8

<b>Nama Pita Multisp ektral</b>	<b><i>Ba nd s</i></b>	<b><i>Wavelength</i> (micrometer)</b>	<b>Resolusi (meter)</b>
(1)	(2)	(3)	(4)
<i>Blue</i>	B2	0.45 – 0.51	30
<i>Green</i>	B3	0.53 – 0.59	30
<i>Red</i>	B4	0.64 – 0.67	30
<i>NIR</i>	B5	0.85 – 0.88	30
<i>SWIR 1</i>	B6	1.57 – 1.65	30
<i>SWIR 2</i>	B7	2.11 – 2.29	30

Sumber : USGS

Indeks komposit dihasilkan melalui transformasi beberapa pita spektral. Biasanya, indeks komposit digunakan untuk tugas tertentu (Hoeser, Bachofer, dan Kuenzer, 2020). Indeks vegetasi yang digunakan untuk membedakan kelas perkebunan kopi, perkebunan nonkopi, dan hutan, yaitu *Normalized Difference Vegetation Index* (NDVI), *Atmospherically Resistant Vegetation Index* (ARVI) (Fan, Fu, Zhang, dan Wu, 2015) dan *Enhanced Vegetation Index 2* (EVI-2) (Bezerra et al., 2020). NDVI merupakan indeks vegetasi yang menggambarkan tingkat kehijauan suatu tanaman yang berasal dari kombinasi matematis antara band merah dan band NIR yang digunakan sebagai indikator keberadaan dan kondisi

vegetasi (Lillesand, Kiefer, dan Chipman, 2015). ARVI merupakan indeks alternatif untuk mengurangi ketergantungan dengan NDVI yang memanfaatkan informasi atmosfer yang terkandung dalam band biru (Rondeaux, Steven, dan Baret, 1996). EVI-2 merupakan alternatif dari EVI tanpa pita biru, yang memiliki konsistensi yang sama di berbagai jenis tutupan lahan dan tidak bergantung pada tutupan lahan serta dikembangkan untuk mengoptimalkan sinyal vegetasi melalui pengaruh dari latar belakang tanah dan sinyal kanopi (Z. Jiang, Huete, Didan, dan Miura, 2008). *Normal Difference Built-up Index* (NDBI) sensitif terhadap lahan bangunan atau lahan terbuka (Hidayati, Suharyadi, dan Danoedoro, 2018). Sementara itu, untuk daerah genangan air menggunakan *Normalized Difference Water Index* (NDWI) (Gautam, Gaurav, Muryan, dan Madural 2015).

Tabel 6. Formula indeks komposit

<b>Indeks Kompo sit</b>	<b>Persamaan <i>band</i> yang digunakan<sup>*)</sup></b>
(1)	(2)
NDVI	$\frac{NIR - Red}{NIR + Red} \quad (5)$
ARVI	$\frac{NIR - \gamma * Red - Blue}{NIR + \gamma * Red - Blue} \quad (6)$
EVI-2	$\frac{NIR - Red}{2.5 * NIR + 2.4 * Red + 1} \quad (7)$
NDBI	$\frac{SWIR1 - NIR}{SWIR1 + NIR} \quad (8)$
NDWI	$\frac{Green - NIR}{Green + NIR} \quad (9)$

### 3.3 Metode Analisis

Tahap awal yang dilakukan pada pengolahan yaitu pre-modelling. Proses ini dilakukan di *Google Earth Engine* (GEE). Pengumpulan data input berupa citra satelit Landsat-8. Input kemudian dilakukan *preprocessing* berupa *cloud filtering* atau koreksi awan, penetapan batas waktu tangkapan citra, dan melakukan *clipping*. Selanjutnya lakukan proses *pan-sharpening* dengan menggabungkan informasi dari dua jenis citra dengan resolusi berbeda. Dalam hal ini, kita menggabungkan citra panchromatic (PAN) dengan resolusi tinggi dan citra multispektral (MS) dengan resolusi lebih rendah. Langkah-langkahnya melibatkan resampling, transformasi, dan fusi informasi. Hasilnya adalah citra dengan resolusi tinggi yang memadukan informasi spektral dari citra MS dan informasi spasial dari citra pan. Pengolahan pan-sharpening penting dalam analisis citra satelit, pemetaan, dan pemantauan lingkungan. Dalam teknik pan-sharpening ini metode yang akan digunakan diantaranya yaitu IHS, Transformasi *Brovey* dan Gram-smicth. Hasil dari proses pan-sharpening adalah citra dengan resolusi tinggi yang memadukan informasi spektral dari citra MS dan informasi spasial dari citra PAN.. Dengan menggabungkan informasi dari kedua jenis citra, kita dapat memperoleh citra yang lebih informatif dan akurat. sehingga menghasilkan refleksi citra satelit sesuai bentuk peta area studi dari penelitian yang disimpan dalam format GeoTIFF. Selain itu dilakukan pemilihan titik sampel atau *geotagging* beserta pelabelan kelas yang terbagi menjadi enam kelas setelah itu lakukan *merge label set* dan menyimpannya dalam format GeoJSON.

Selanjutnya proses *extract feature* dilakukan pada *Google Colaboratory Notebook* dengan bahasa *python*. *Extract feature* memiliki Tujuan yaitu melakukan perhitungan dan perbandingan yang digunakan untuk mengklasifikasikan ciri-ciri yang dimiliki oleh suatu citra. *Extract feature* diambil dari data GeoJSON yang


berisi lokasi sejumlah titik sampel dan GeoTIFF berupa tangkapan refleksi citra akan menghasilkan informasi pita multispektral dari lokasi: titik sampel hasil geotagging. Pita multispektral yang digunakan yaitu pita yang terdapat pada kedua citra satelit, yaitu *blue*, *green*, *red*, NIR, SWIR 1, dan SWIR2. Refleksi citra berupa kumpulan piksel yang pada setiap pikselnya terdapat informasi pita multispektral. Lokasi piksel terpilih berdasarkan titik sampel, sehingga terkumpul data sebanyak jumlah lokasi titik sampel yang disimpan dalam bentuk array.

Analisis deskriptif dilakukan untuk tujuan pemilihan fitur terbaik penciri lahan perkebunan kopi menggunakan data pita multispektral dan indeks komposit. Indeks komposit yang digunakan, yaitu NDVI, ARVI, EVI-2, NDBI, dan NDWI. Data *array* dikelompokkan pada rentang tertentu dengan *jenks natural breaks*. *Jenks natural breaks* merupakan jenis metode klasifikasi optimal yang bertujuan untuk memaksimalkan varians antarkelas dan meminimalkan varians dalam kelas. Pengelompokan data antarkelas berdasarkan informasi yang melekat dalam data (*data-driven*). Rentang level dibagi menjadi lima, yaitu *very low*, *low*, *medium*, *high*, dan *very high* (Verde et al., 2020). Rentang level tersebut sebelumnya diuji menggunakan pengujian *Goodness of Variance Fit* (GVF) yang jika menghasilkan nilai mendekati satu, maka menunjukkan varians antar kelas yang dibagi sudah optimum. Selanjutnya dilakukan penghitungan nilai rata-rata terhadap kelas masing-masing dan mengelompokkan menurut levelnya serta divisualisasikan dalam bentuk *heatmap* untuk memudahkan perbandingan nilai rata-rata kelas yang telah dikelompokkan.

Untuk tujuan mengidentifikasi model klasifikasi terbaik penciri lahan perkebunan kopi, dilakukan dengan mengimplementasikan algoritma *supervised classificat* pada *machine learning* dan *deep learning*. Pada *machine learning*,

digunakan algoritma klasifikasi, yaitu *Support Vector Machines* (SVM), *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost). Sementara itu, pada *deep learning* menggunakan *Multi-Layer Perceptron* (MLP) dan *Convolutional Neural Network* (CNN- 1D). Pada *machine learning* dilakukan *hyperparameter tuning* menggunakan *grid search* agar mendapat *hyperparameter* terbaik dalam membangun model berdasarkan data. Kemudian dilakukan evaluasi model menggunakan *stratified k-fold cross validation* dengan nilai k sama dengan lima untuk menghindari efek kebetulan dan menghindari kemungkinan *overfitting* agar lebih yakin dalam pemilihan model terbaik. Penilaian model berdasarkan beberapa kriteria, seperti akurasi, presisi, *recall*, dan F1-score.

Model klasifikasi terbaik digunakan untuk melakukan prediksi piksel yang terdapat pada file GeoTIFF atau seluruh wilayah Kabupaten OKU Selatan. Kemudian untuk tujuan estimasi luas lahan perkebunan kopi, hasil klasifikasi seluruh piksel, diambil jumlah pikselnya yang terprediksi atau terklasifikasi menjadi kelas perkebunan kopi. Satuan pada citra satelit dalam satu piksel memiliki satuan m sehingga perlu dilakukan pengkonversian menjadi satuan hektar (Ha) sama seperti yang digunakan oleh BPS agar bisa dibandingkan.



Gambar 9. Alur *workflow* penelitian

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Identifikasi Fitur Terbaik Penciri Citra Lahan Perkebunan Kopi

Untuk menganalisis efek dari berbagai metode *pan-sharpening*, analisis deskriptif digunakan untuk mengidentifikasi fitur pada citra satelit Landsat-8. Pita multispektral digunakan untuk membentuk indeks komposit, dan seluruh pita multispektral serta indeks komposit Landsat-8 dinormalisasi dan distandardisasi sehingga rentang nilai antara 0 dan 1. Kemudian dilakukan perhitungan *Goodness of Variance Fit* (GVF) untuk setiap fitur sebelum membagi menjadi lima level dengan metode *jenks natural breaks*. Hasil menunjukkan nilai perhitungan GVF mendekati satu pada seluruh fitur, artinya pembagian level sudah optimal atau variasi antar kelas terbagi secara optimum sehingga dapat dikelompokkan menurut levelnya.

Tabel 7. Hasil perhitungan GVF fitur pada citra satelit

Fitur	Jenis	Nilai GVF			
		Asli	IHS	Brovey	Gram-Schmidt
(1)	(2)	(3)	(4)	(5)	(5)
<i>Blue</i>	Indeks Komposit	0,9243	0.9218	0,9057	0,9156
<i>Green</i>		0,9137	0.9219	0,9150	0,9156
<i>Red</i>		0,8999	0.9254	0,9218	0,9156
NIR ( <i>Near-Infrared</i> )		0,9474	0.9474	0,9474	0,9474
SWIR ( <i>Short Wave Infrared 1</i> )		0,9399	0.9399	0,9399	0,9399
SWIR2 ( <i>Short Wave Infrared 2</i> )		0,9375	0.9375	0,9375	0,9375
NDBI			0.9524	0,9524	0,9524

(Normal Difference Built-up Index)		0,9524			
NDWI (Normalized Difference Water Index)		0,9597	0.9582	0,9611	0,9565
NDVI (Normalized Difference Vegetation Index)		0,9569	0.9546	0,9560	0,9588
EVI-2 (Enhanced Vegetation Index 2)		0,9519	0.9579	0,9533	0,9563


Selanjutnya, dilakukan penghitungan nilai rata-rata terhadap kelas tutupan lahan masing-masing dan pengelompokkan menurut levelnya. Lima rentang level yang dibentuk, yaitu *very low*, *low*, *medium*, *high*, dan *very high*. Berikut disajikan pada Tabel 8 rentang pengelompokkan level berdasarkan perhitungan *jenks natural breaks*.

Tabel 8. Rentang kelompok level pada citra satelit


Kelompok Level	Rentang Nilai Mean			
	Asli	IHS	Brovey	Gram-Schmidt
(1)	(2)	(3)	(4)	(5)
<i>Very Low</i>	0 – 0.212	0 – 0.237	0 – 0.2325	0 – 0.2352
<i>Low</i>	0.212 – 0.385	0.237 – 0.427	0.2326 – 0.4298	0.2353 – 0.4293
<i>Medium</i>	0.385 – 0.563	0.427 – 0.600	0.4299 – 0.6009	0.4294 – 0.5972
<i>High</i>	0.563 – 0.759	0.600 – 0.807	0.6010 – 0.8044	0.5973 – 0.7994
<i>Very High</i>	0.759 – 1	0.807 – 1	0.8045 – 1	0.7995 – 1

Berdasarkan hasil tersebut dapat dibentuk *heatmap* pada masing masing citra satelit untuk mengetahui distribusi fitur tiap kelas. Distribusi fitur tiap kelas ditunjukkan dengan *heatmap* pada gambar 10, 11, 12 dan 13.







Gambar 11. Distribusi fitur pada citra Landsat-8



Gambar 12. Distribusi fitur pada citra Landsat-8 hasil *Pan-sharpening* IHS



Gambar 13. Distribusi fitur pada citra Landsat-8 hasil *Pan-sharpening Brovey*



Gambar 14. Distribusi fitur pada citra Landsat-8 hasil *Pan-sharpening Gram-Schmidt*

Diperoleh informasi dari Gambar *heatmap* mengenai perbedaan nilai band pada tiap-tiap kelas. Nilai rata-rata pita multispektral atau band bawaan (RGB, NIR, SWIR 1, dan SWIR 2) dari pan-sharpening IHS, *Brovey*, ataupun *Gram-Schmidt*

hampir tidak ada perbedaan antarkelas atau serupa, sehingga sulit untuk membedakan kelas-kelas lainnya. Oleh karena itu, indeks komposit yang merupakan kombinasi dari beberapa band yang ada cukup dapat membantu untuk membedakan kelas tutupan lahan. Penciri lahan perkebunan kopi didapatkan nilai yang mirip, baik IHS, *Brovey*, maupun *Gram-Schmidt*, yaitu pada fitur NDWI berada pada level very low; fitur SWIR 2 berada pada level low; SWIR2 berada pada level medium; EVI-2 berada pada level high dan indeks vegetasi NDVI, dan ARVI berada pada level very high, namun pada fitur RGB (red, green, dan blue) berada pada level yang cukup beragam untuk citra asli, pan-sharpening IHS, *Brovey*, ataupun *Gram-Schmidt*.

Secara lebih rinci, NDBI mudah untuk membedakan kelas bangunan dan tanah dengan kelas lainnya, ditandai dengan perolehan nilai mean yang tinggi dari pada kelas lain dan kelas bangunan mempunyai nilai lebih tinggi daripada kelas tanah. NDWI juga mampu untuk membedakan kelas air dengan kelas lainnya. Sementara itu, pada indeks vegetasi (NDVI, EVI-2, dan ARVI) belum bisa membedakan kelas perkebunan kopi, perkebunan non-kopi, dan hutan baik pada citra asli, pan-sharpening IHS, *Brovey*, ataupun *Gram-Schmidt* kecuali kelas hutan pada pan-sharpening *Brovey*. Namun jika diperhatikan lebih lanjut, dapat dilihat bahwa pada citra asli dan ketiga pan-sharpening memiliki pola. Kelas perkebunan kopi memiliki nilai yang lebih rendah daripada kelas perkebunan non-kopi ataupun hutan pada indeks vegetasi dan nilai yang lebih tinggi pada NDBI dan NDWI. Dengan menggabungkan informasi ini, mesin mungkin akan mampu membedakan antara kelas tersebut. Dengan begitu, bila nilai indeks suatu piksel berada pada level yang sama untuk kelas perkebunan kopi, perkebunan nonkopi, dan hutan, serta nilai yang paling rendah pada indeks vegetasi, yaitu NDVI, EVI-2, dan ARVI tetapi lebih tinggi pada NDBI dan NDWI maka kemungkinan besar piksel tersebut mewakili

perkebunan kopi.

#### 4.2 Pembentukan Model Klasifikasi Terbaik Dalam Mendeteksi Lahan Perkebunan Kopi

Untuk memperoleh model klasifikasi terbaik dalam mendeteksi lahan perkebunan kopi, menggunakan *machine learning* dan *deep learning*. Pada *machine learning* digunakan algoritma klasifikasi, yaitu *Support Vector Machines* (SVM), *random forest*, dan *Extreme Gradient Boosting* (XGBoost). Sementara itu, pada *deep learning* menggunakan *Multi-Layer Perceptron* (MLP) dan *Convolutional Neural Network* (CNN-1D). Klasifikasi dilakukan terhadap masing-masing data *pan-sharpening* IHS, *Brovey*, *Gram-Schmidt* dan data asli dengan fitur dan resolusi spasial yang berbeda. Seluruh algoritma akan dipilih berdasarkan perbandingan kriteria penilaian, yaitu nilai akurasi, presisi, *recall*, dan *F1-score*. Berikut performa dari model *machine learning* dan model *deep learning* yang digunakan, serta perbandingannya dapat dilihat pada Tabel 9 dan 10. Tabel tersebut menunjukkan hasil *stratified 5-fold cross validation* pada *machine learning* yang sudah dilakukan *hyperparameter tuning* menggunakan *grid search*.

Tabel 9. Perbandingan performa model *machine learning* menggunakan *stratified 5-fold cross validation*

Data	Algoritma	Akurasi	Presisi	Recall	F1-score
Asli	SVM	80,35%	80,53%	80,35%	80,38%
	Random Forest	79,78%	80,05%	79,78%	79,82%
	XGBoost	78,56%	78,77%	78,56%	78,58%
	SVM	82,98%	83,42 %	82,98 %	83,05%

IHS	<i>Random Forest</i>	82,40%	82,78%	82,40%	82,48%
	XGBoost	82,88%	83,16%	82,88%	82,93%
<i>Brovey</i>	<b>SVM</b>	<b>83,49%</b>	<b>83,98 %</b>	<b>83,49 %</b>	<b>83,59%</b>
	<i>Random Forest</i>	82,53%	82,97%	82,53%	82,63%
	XGBoost	83,17%	83,37%	83,17%	83,18%
<i>Gram-Schmidt</i>	SVM	80,10%	80,77 %	80,10 %	80,16%
	<b><i>Random Forest</i></b>	<b>80,99%</b>	<b>81,46%</b>	<b>80,99%</b>	<b>81,13%</b>
	XGBoost	80,96%	81,32%	80,96%	81,07%

Berdasarkan Tabel 9, hasil *machine learning* pada citra asli menunjukkan algoritma SVM mendapatkan persentase tertinggi pada setiap aspek dimana memiliki akurasi sebesar 80,35 persen, presisi sebesar 80,53 persen; *recall* sebesar 80,35 persen; dan F1-score sebesar 80,38 persen. Sedangkan pada Pan-sharpening IHS menunjukkan bahwa algoritma SVM mendapatkan persentase tertinggi di seluruh aspek penilaian, yaitu nilai akurasi sebesar 82,98 persen presisi sebesar 83,42 persen; *recall* sebesar 82,98 persen; dan F1-score sebesar 83,05 persen. Sementara itu, pada Pan-sharpening *Brovey* diperoleh juga algoritma SVM dengan persentase tertinggi, yaitu nilai akurasi sebesar 83,49 persen; presisi sebesar 83,98 persen; *recall* sebesar 83,49 persen; dan F1-score sebesar 83,59 persen. Sedangkan pada Pan-sharpening *Gram-schmidt* algoritma *Random Forest* dengan persentase tertinggi, yaitu nilai akurasi sebesar 80,99 persen; presisi sebesar 81,46 persen; *recall* sebesar 80,99 persen; dan F1-score sebesar 81,13 persen.

Algoritma Random forest mendapat persentase terendah ditinjau dari nilai akurasi dan F1-score pada citra asli maupun *Pan-sharpening*, kecuali pada *Gram-Schmidt*. Persentase akurasi sebesar 80,67 persen dan F1-score sebesar 80,79 persen pada IHS, sedangkan pada *Brovey* persentase akurasi sebesar 81,56 persen dan F1-

score sebesar 81,67 persen. Sebagian besar algoritma menunjukkan hasil performa lebih baik pada penggunaan data Pan-sharpening IHS daripada data Pan-sharpening *Brovey*, ataupun *Gram-Schmidt*. Hasil juga menunjukkan bahwa performa Pan-sharpening *Gram-schmidt* memiliki hasil paling buruk dibandingkan dua metode pan-sharpening lainnya, tetapi masih lebih bagus dari citra aslinya. Hal yang bisa menyebabkan perbedaan performa algoritma adalah resolusi yang dimiliki pada Setiap proses masing-masing Pan-sharpening, artinya algoritma Pan-sharpening memiliki pengaruh terhadap hasil performa model. Selain itu, juga terdapat perbedaan panjang gelombang (wavelength) yang digunakan oleh masing-masing Pan-sharpening yang juga dapat menjadi penyebab perbedaan performa. Berdasarkan hasil yang diperoleh dipilih algoritma machine learning terbaik mendeteksi lahan perkebunan kopi, yaitu SVM pada IHS, *Brovey* ataupun *Gram-schmidt* pada Landsat-8 yang kemudian akan dibandingkan dengan hasil deep learning yang juga dievaluasi menggunakan stratified 5-fold cross validation.

Tabel 10. Perbandingan performa model *machine learning* terbaik dengan *deep Learning* menggunakan *stratified 5-fold cross validation*


<b>Data</b>	<b>Algoritma</b>	<b>Akurasi</b>	<b>Presisi</b>	<b>Recall</b>	<b>F1-score</b>
Asli	<b>SVM</b>	<b>80,35%</b>	<b>80,53%</b>	<b>80,35%</b>	<b>80,38%</b>
	MLP	79,14%	80,90%	77,41%	79,11%
	CNN	77,83%	78,97%	75,90%	81,40%
IHS	<b>SVM</b>	<b>82,98%</b>	<b>83,42 %</b>	<b>82,98 %</b>	<b>83,05%</b>
	MLP	81,47%	83,23%	79,78%	81,46%
	CNN	79,98%	81,73%	77,50%	79,55%
<i>Brovey</i>	<b>SVM</b>	<b>83,49%</b>	<b>83,98 %</b>	<b>83,49 %</b>	<b>83,59%</b>
	<i>MLP</i>	81,76%	83,37%	80,00%	81,65%

	CNN	79,84%	81,72%	77,21%	79,40%
<i>Gram-Schmidt</i>	<i>Random Forest</i>	80,99%	81,46%	80,99%	81,13%
	<b>MLP</b>	<b>82,12%</b>	<b>83,59%</b>	<b>80,16%</b>	<b>81,84%</b>
	CNN	80,61%	82,76%	78,75%	80,70%

Hasil *deep learning* pada tabel 10 menunjukkan algoritma MLP mendapatkan persentase yang lebih tinggi daripada algoritma CNN-1D. Didapatkan persentase nilai akurasi sebesar 81,47 persen dan F1-score sebesar 81,46 persen pada IHS, dan pada *Brovey* mendapat persentase nilai akurasi sebesar 81,76 persen dan F1-score sebesar 81,65 persen, sedangkan pada *Gram-schmidt* mendapatkan persentase nilai akurasi sebesar 82,12 persen dan F1-score sebesar 81,84 persen. Kemudian algoritma CNN-1D pada IHS persentase nilai akurasi sebesar 79,98 persen dan F1-score sebesar 79,55 persen, dan pada *Brovey* mendapat persentase nilai akurasi sebesar 79,85 persen dan F1-score sebesar 79,40 persen, sedangkan pada *Gram-schmidt* mendapatkan persentase nilai akurasi sebesar 80,61 persen dan F1-score sebesar 80,70 persen. Hasil menunjukkan data *Brovey* mendapatkan nilai persentase yang lebih tinggi daripada data IHS dan *Gram-schmidt* atau dengan kata lain pengaruh resolusi spasial juga berlaku pada metode *deep learning* dalam menghasilkan performa model. Berdasarkan analisis deskriptif yang telah dijelaskan, maka hasil model terbaik dipilih algoritma SVM pada *Brovey* karena memiliki nilai tertinggi di seluruh aspek penilaian.

Setelah melakukan serangkaian perbandingan metode *pan-sharpening*, ditemukan bahwa metode *Brovey* memberikan hasil terbaik dalam hal akurasi. Sebagai langkah selanjutnya, penting untuk mengevaluasi performa metode ini secara lebih mendetail. Untuk itu, kita akan menggunakan confusion matrix sebagai alat lanjutan. Confusion matrix memungkinkan kita untuk mengidentifikasi secara

spesifik bagaimana metode Brovey dalam mengklasifikasikan piksel citra, memberikan gambaran yang jelas mengenai tingkat akurasi, presisi, dan recall dari hasil pan-sharpening. Dengan analisis ini, kita dapat memastikan validitas dan efektivitas metode *Brovey* dalam konteks penggunaan yang lebih luas. Hasil ketelitian interpretasi untuk penelitian ini sebesar 83,59% dan citra hasil tranformasi *Brovey* tertuang pada gambar 15.



Gambar 15. Confusion Matrix citra Landsat-8 hasil *Pan-sharpening Brovey*

#### 4.3 Mengestimasi Luas Lahan Perkebunan Kopi Menggunakan Model Terbaik

Hasil estimasi luas lahan perkebunan kopi menggunakan model SVM pada



citra satelit Landsat-8 dengan menggunakan data hasil pan-sharpening *Brovey*, diperoleh luas perkebunan kopi di kabupaten OKU Selatan tahun 2022 sebesar 120.501,56 Ha atau lebih 30.999,56 Ha (25,72 persen) bila dibandingkan data tabel dinamis BPS provinsi Sumatera Selatan sebesar 89.260 Ha. Sementara itu, bila dibandingkan data tabel dinamis BPS Kabupaten OKU Selatan sebesar 89.050 Ha yang didapatkan melalui akumulasi luas lahan perkebunan kopi tiap kecamatan, hasil estimasi lebih luas 30.999,56 Ha (29,73 persen). Hal ini dikarenakan data lahan perkebunan kopi didapatkan bersumber dari laporan yang disediakan oleh Dinas Perkebunan sesuai level administrasi. Artinya data tabel dinamis BPS provinsi bersumber dari dinas perkebunan provinsi sedangkan data tabel dinamis BPS kabupaten bersumber dari dinas perkebunan kabupaten..


Tabel 11. Perbandingan hasil estimasi luas perkebunan kopi dengan data tabel dinamis berdasarkan kecamatan di Kabupaten OKU Selatan tahun 2022

<i>Kecamatan</i>	<i>Luas Lahan (Ha)</i>	<i>Estimasi (Ha)</i>	<i>Selisih (Ha)</i>
Mekakau Ilir	9228	5667,53	3560,47
Banding Agung	4356	4080,13	275,87
Warkuk Ranau Selatan	5847	5929,92	82,92
BPR Ranau Tengah	9264	9046	218
Buay Pemaca	6640	21560,22	14920,22
Simpang	101	5608,83	5507,83
Buana Pemaca	1971	3254,43	1283,43
Buay Rawan	950	4061,36	3111,36
Buay Sandang Aji	5051	7405,97	2354,97

Tiga Dihaji	3511	2420,03	1090,97
Buay Runjung	3091	5857,47	2766,47
Runjung Agung	5871	4942,17	928,83
Kisam Tinggi	9015	15833,86	6818,86
Muaradua Kisam	6114	3669,49	2444,51
Kisam Ilir	4218	6181,54	1963,54
Pulau Beringin	6035	12681,67	6646,67
Sindang Danau	6065	6244,22	119,78
Sungai Are	2174	5490,03	3316,03
Total	89502	126.721,67	37,251,67
Kabupaten Oku Selatan	89502	126.721,67	37,251,67

Pada tabel 11 dapat dilihat bahwa terdapat selisih yang cukup besar pada tiap kecamatan antara luas lahan perkebunan dengan estimasi luas lahan perkebunan. Hal ini dikarenakan tingkat ketelitian pada wilayah administrasi yang semakin kecil akan menimbulkan selisih yang semakin besar. Selain itu, selisih estimasi lahan perkebunan kopi juga mungkin disebabkan karena kesalahan klasifikasi model SVM terhadap kelas perkebunan non-kopi. Kemudian, juga terdapat piksel klasifikasi kelas perkebunan kopi yang tidak mengumpul sepenuhnya pada satu tempat, sehingga dapat menjadi penyebab perbedaan cukup besar atau terdapat selisih hasil estimasi dengan data official statistics.

Metode pengumpulan data yang dilakukan pada Survei Perusahaan Perkebunan (SKB) perkebunan kopi dilakukan dengan metode self-enumeration yang diisi oleh pemilik perkebunan berdasarkan hasil estimasinya masing-masing. Hal ini juga dapat menjadi penyebab kurang tepatnya laporan luas lahan dengan keadaan sesungguhnya. Berikut peta tutupan lahan Kabupaten OKU Selatan.



Gambar 16. Hasil klasifikasi model SVM pada citra satelit Landsat-8 data *Brove*

## **BAB V**

### **KESIMPULAN DAN SARAN**

#### **5.1 Kesimpulan**

Penelitian ini mampu mendeteksi lahan perkebunan kopi termasuk wilayah yang sulit dijangkau atau menurut batas wilayah penelitian. Berdasarkan hasil dan pembahasan yang dijelaskan sebelumnya, beberapa hal yang dapat disimpulkan.

1. Untuk mengetahui efek dari berbagai metode pan-sharpening dalam mendeteksi lahan perkebunan kopi pada citra satelit Landsat-8, penelitian ini menganalisis perbedaan nilai indeks vegetasi (NDVI, EVI, dan ARVI). Hasil menunjukkan bahwa lahan perkebunan kopi cenderung memiliki nilai indeks vegetasi yang lebih rendah, tetapi memiliki nilai yang lebih tinggi pada NDBI dan NDWI dibandingkan dengan kelas perkebunan non-kopi atau hutan.
2. Untuk mendapat model klasifikasi terbaik dalam mendeteksi lahan perkebunan kopi, penelitian ini berhasil menghasilkan model SVM pada data *Brovey* yang menunjukkan performa unggul. Hal ini ditunjukkan dari performa nilai akurasi, presisi, recall, dan F1- score yang tertinggi, yaitu akurasi sebesar 83,49 persen dan F1-score sebesar 83,59 persen.
3. Untuk mengestimasi luas lahan perkebunan kopi menggunakan model terbaik *SVM*, didapatkan hasil estimasi luas perkebunan kopi di kabupaten OKU Selatan tahun 2022 seluas 120.501,56 Ha pada citra satelit Landsat-8 hasil pan-sharpening *Brovey*

## 5.2 Saran

Berdasarkan hasil dan pembahasan, terdapat beberapa saran yang dapat diajukan.

1. Untuk penelitian selanjutnya, melakukan post classification processing, karena masih banyak piksel hasil klasifikasi tutupan lahan yang tidak sesuai pada kelas yang seharusnya. Misalnya terdapat piksel hutan di tengah-tengah perkebunan nonkopi atau bayangan awan yang terklasifikasi menjadi piksel perkebunan kopi.
2. Untuk pengembangan lebih lanjut dari penelitian ini, fokuskan penelitian pada pengembangan atau perbaikan metode pan-sharpening. Hal ini karna proses pan-sharpening sering kali mengorbankan informasi spektral untuk meningkatkan resolusi spasial. Ini dapat mengakibatkan penurunan dalam kemampuan untuk membedakan antara objek atau fitur berdasarkan karakteristik spektralnya. Pengembangan ini dapat mencakup pembuatan algoritma baru atau penyesuaian parameter yang lebih baik untuk menciptakan citra gabungan yang lebih akurat dan informatif.
3. Untuk mendapatkan ketepatan batas wilayah administrasi, instansi pemerintah perlu melakukan integrasi atau kesepakatan bersama mengenai *shapefile* batas wilayah administrasi yang digunakan untuk kepentingan masing-masing instansi.

## DAFTAR PUSTAKA

- “Coffee Shops - Global Strategic Business Report” [Online]. Available: <https://finance.yahoo.com/news/global-coffee-shops-strategic-business-085800157.html?>. Diakses 09 November 2021.
- “Coffee : World Markets and Trade” [Online]. Available: <https://apps.fas.usda.gov/psdonline/circulars/coffee.pdf>.
- Y. Nurhanisah. (2023). Provinsi Penghasil Kopi Terbesar. <https://indonesiabaik.id/infografis/provinsi-penghasil-kopi-terbesar>. Diakses 09 November 2021
- Direktorat Statistik Tanaman, Pangan Hortikultura, and Perkebunan, Statistik Kopi Indonesia 2021: Badan Pusat Statistik, 2022.
- D. W. Triscowati and A. W. Wijayanto, "Peluang dan tantangan dalam pemanfaatan teknologi penginderaan jauh dan machine learning untuk prediksi data tanaman pangan yang lebih akurat," in Seminar Nasional Official Statistics, 2019, pp. 177-187..
- Aziz, M. “Pemanfaatan Citra Sentinel-2A untuk Estimasi Produksi Tanaman Kopi di Sebagian Wilayah Kabupaten Temanggung”,2019.
- H. Dibs, H. Ali Hasab, A. S .Mahmoud , N. Al-Ansari, “Fusion Methods and Multi-classifiers to Improve Land Cover Estimation Using Remote Sensing Analysis”, Geotechnical and Geological Engineering, vol. 39, p. 5825, 2021.
- N. Yusof, H. Z. M. Shafri, and N. S. N. Shaharum, "The use of Landsat-8 and Sentinel-2 imageries in detecting and mapping rubber trees," Journal of Rubber Research, vol. 24, pp. 121-135, 2021
- J. jagannathan, C. Divya, “Deep learning for the prediction and classification of land use and land cover changes using deep convolutional neural network”, IEEE, vol. 8, 2020.
- Damayanti, A. M. Liyantono, “Identifikasi Tanaman Kopi (Coffea) di Provinsi Jawa Barat berbasis Machine Learning SVM dan Random Forest Citra Satelit Landsat-8”,2021.
- BPS. (2021-2022). Luas Tanaman Perkebunan (Hektare). <https://sumsel.bps.go.id/indicator/54/414/1/luas-tanaman-perkebunan.html>. Diakses 09 November 2021
- N. Yusof, H. Z. M. Shafri, and N. S. N. Shaharum, "The use of Landsat-8 and Sentinel-2 imageries in detecting and mapping rubber trees," Journal of Rubber Research, vol. 24, pp. 121-135, 2021
- C. Haub, L. Kleinewillinghöfer, V. Garcia Millan (EFTAS), and A. Di Gregorio (FAO), "Protocol For Land Cover Validation," SIGMA – Stimulating Innovation for Global Monitoring of Agriculture, 2015..
- Sitanggang, G., Carolita I., B.H. Trisasongko. “Aplikasi Teknik dan Metode Fusi Data Optik ETM-Plus Landsat dan Sar Radarsat untuk Ekstraksi Informasi Geologi Pertambangan Batu Bara”. Lapan. Vol. 6, 2004
- Wandayani, A, “Perbandingan Metode Brovey dan PCA dalam Fusi Citra Panchromatic dan Multispectral. Laporan Tugas Akhir. Departemen Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Institut Pertanian Bogor”,2007
- Daenodoro, Projo, “Pengantar Penginderaan Jauh Digital.”,2012
- USGS. Landsat 8 Band Designations. <https://www.usgs.gov/media/images/landsat-8-band-designations>.

Diakses 8 Maret 2022.

- T. Hoeser, F. Bachofer, and C. Kuenzer, "Object detection and imagesegmentation with deep learning on Earth observation data: A review—Part II: Applications," *Remote Sensing*, vol. 12, p. 3053, 2020.
- F. G. S. Bezerra, A. P. D. Aguiar, R. C. d. S. Alvalá, A. Giarolla, K. R. A. Bezerra, P. V. P. S. Lima, et al., "Analysis of areas undergoing desertification, using EVI2 multi-temporal data based on MODIS imagery as indicator," *Ecological Indicators*, vol. 117, p. 106579, 2020.
- T. Lillesand, R. W. Kiefer, and J. Chipman, *Remote sensing and image interpretation*: John Wiley & Sons, 2015.
- G. Rondeaux, M. Steven, and F. Baret, "Optimization of soil-adjusted vegetation indices," *Remote sensing of environment*, vol. 55, pp. 95-107, 1996.
- Z. Jiang, A. R. Huete, K. Didan, and T. Miura, "Development of a two-band enhanced vegetation index without a blue band," *Remote sensing of Environment*, vol. 112, pp. 3833-3845, 2008.
- I. N. Hidayati, R. Suharyadi, and P. Danoedoro, "Developing an extraction method of urban built- up area based on remote sensing imagery transformation index," in *Forum Geografi*, 2018, pp. 96- 108.
- V. K. Gautam, P. K. Gaurav, P. Murugan, and M. Annadurai, "Assessment of surface water Dynamicsin Bangalore using WRI, NDWI, MNDWI, supervised classification and KT transformation," *Aquatic Procedia*, vol. 4, pp. 739-746, 2015.
- N. Verde, I. P. Kokkoris, C. Georgiadis, D. Kaimaris, P. Dimopoulos, I. Mitsopoulos, et al., "National scale land cover classification for ecosystem services mapping and assessment, using multitemporal copernicus EO data and google earth engine," *Remote Sensing*, vol. 12, p. 3303, 2020.
- Y. Chen, P. Dou, and X. Yang, "Improving land use/cover classification with a multiple classifier system using AdaBoost integration technique," *Remote Sensing*, vol. 9, p. 1055, 2017.
- L. Breiman, "Random forests," *Machine learning*, vol. 45, pp. 5-32, 2001.
- D. W. Triscowati, B. Sartono, A. Kurnia, D. D. Domiri, and A. W. Wijayanto, "Multitemporal remote sensing data for classification of food crops plant phase using supervised random forest," in *Sixth Geoinformation Science Symposium*, 2019, p. 1131102.
- K. Budholiya, S. K. Shrivastava, and V. Sharma, "An optimized XGBoost based diagnostic system for effective prediction of heart disease," *Journal of King Saud University-Computer and Information Sciences*, 2020.
- M. S. T. Putra and Y. Azhar, "Perbandingan Model Logistic Regression dan Artificial Neural Network pada Prediksi Pembatalan Hotel," *JISKA (Jurnal Informatika Sunan Kalijaga)*, vol. 6, pp. 29-37, 2021.
- W. Jiang, G. He, T. Long, Y. Ni, H. Liu, Y. Peng, et al., "Multilayer perceptron neural network for surface water extraction in Landsat 8 OLI satellite images," *Remote Sensing*, vol. 10, p. 755, 2018.
- F. Hu, G.-S. Xia, J. Hu, and L. Zhang, "Transferring deep convolutional neural networks for the scene classification of high-resolution remote sensing imagery," *Remote Sensing*, vol. 7, pp. 14680- 14707, 2015.
- A. Peryanto, A. Yudhana, and R. Umar, "Klasifikasi Citra Menggunakan Convolutional Neural Network dan K Fold Cross Validation," *Journal of Applied Informatics and computing*, vol. 4, pp. 45-51, 2020.

M. Berndtsson, J. Hansson, B. Olsson, and B. Lundell, Thesis projects: a guide for students in computer science and information systems: SpringerScience & Business Media, 2007



## LAMPIRAN

### Lampiran 1. *Hyperparameter tuning SVM*

```
{'algo__C': array([1.e-03, 1.e-02, 1.e-01, 1.e+00, 1.e+01, 1.e+02, 1.e+03]),  
 'algo__gamma': array([1.e-03, 1.e-02, 1.e-01, 1.e+00, 1.e+01, 1.e+02, 1.e+03])}
```

Best params:

```
{'algo__C': 10.0, 'algo__gamma': 1.0}
```

### Lampiran 2. *Hyperparameter tuning random forest*

```
{'algo__max_depth': [20, 50, 80],  
 'algo__max_features': [0.3, 0.6, 0.8],  
 'algo__min_samples_leaf': [1, 5, 10],  
 'algo__n_estimators': [100, 150, 200]}
```

Best params:

```
{'algo__max_depth': 20, 'algo__max_features': 0.8, 'algo__min_samples_leaf': 1, 'algo__n_estimators': 200}
```

### Lampiran 3. *Hyperparameter tuning XGBoost*

```
{'algo__colsample_bytree': [0.4, 0.5],  
 'algo__gamma': [1, 2],  
 'algo__learning_rate': [0.01, 0.05],  
 'algo__max_depth': [2, 3, 4],  
 'algo__n_estimators': [100, 150, 200]}
```

Best params:

```
{'algo__colsample_bytree': 0.4, 'algo__gamma': 1, 'algo__learning_rate': 0.05, 'algo__max_depth': 4, 'algo__n_estimators': 200}
```

### Lampiran 4. *5-fold SVM*

Asli:

	fit_time	score_time	test_accuracy	test_prec_macro	test_rec_macro
0	0.090759	0.036337	0.810000	0.813485	0.810000
1	0.098234	0.038704	0.820000	0.822806	0.820000
2	0.097624	0.037355	0.836667	0.841808	0.836667
3	0.090959	0.036356	0.823333	0.830517	0.823333
4	0.090006	0.038473	0.833333	0.834186	0.833333
5	0.089561	0.036532	0.833333	0.842657	0.833333

	test_f1_macro
0	0.809006
1	0.821165
2	0.837551
3	0.824995
4	0.831926
5	0.833507

Accuracy: 0.8261 | Precision: 0.8309 | Recall: 0.8261 | F1-Score: 0.8264  
[Parallel(n\_jobs=-1)]: Done 6 out of 6 | elapsed: 0.4s finished

IHS:

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 0.189747 0.081935 0.840000 0.844072 0.840000
1 0.198702 0.090064 0.876667 0.881380 0.876667
2 0.186592 0.072567 0.816667 0.825193 0.816667
3 0.180242 0.076199 0.810000 0.820317 0.810000
4 0.192297 0.081304 0.863333 0.863921 0.863333
5 0.174745 0.038626 0.836667 0.845002 0.836667

test_f1_macro
0 0.840778
1 0.877301
2 0.818705
3 0.811914
4 0.862869
5 0.838449
Accuracy: 0.8406 | Precision: 0.8466 | Recall: 0.8406 | F1-Score: 0.8417
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 4.2s finished
```

*Brovey*

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 0.092479 0.040424 0.820000 0.828255 0.820000
1 0.089826 0.044584 0.873333 0.878488 0.873333
2 0.089646 0.043246 0.813333 0.817849 0.813333
3 0.085659 0.038965 0.803333 0.814290 0.803333
4 0.092611 0.039274 0.870000 0.870206 0.870000
5 0.098317 0.036908 0.830000 0.837866 0.830000

test_f1_macro
0 0.821567
1 0.873458
2 0.814143
3 0.804930
4 0.869169
5 0.831766
Accuracy: 0.8350 | Precision: 0.8412 | Recall: 0.8350 | F1-Score: 0.8358
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 0.4s finished
```

*Gram-schmidt*

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro
0 0.102631 0.047519 0.786111 0.791996 0.786111
1 0.103281 0.045582 0.825000 0.831268 0.825000
2 0.090637 0.045864 0.777778 0.788628 0.777778
3 0.091351 0.048066 0.825000 0.829585 0.825000
4 0.055551 0.027403 0.794444 0.804190 0.794444

test_f1_macro
0 0.788065
1 0.827118
2 0.781328
3 0.825174
4 0.796881
Accuracy: 0.8017 | Precision: 0.8091 | Recall: 0.8017 | F1-Score: 0.8037
[Parallel(n_jobs=-1)]: Done 5 out of 5 | elapsed: 0.4s finished
```

## Lampiran 5. 5-fold random forest

Asli:

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 1.132616 0.058992 0.793333 0.798789 0.793333
1 1.131829 0.048993 0.806667 0.811368 0.806667
2 1.064230 0.055449 0.820000 0.829853 0.820000
3 1.106392 0.053116 0.803333 0.804537 0.803333
4 1.071269 0.046859 0.836667 0.840043 0.836667
5 1.075667 0.043612 0.803333 0.814375 0.803333

test_f1_macro
0 0.795287
1 0.808472
2 0.821069
3 0.802529
4 0.836507
5 0.806567
Accuracy: 0.8106 | Precision: 0.8165 | Recall: 0.8106 | F1-Score: 0.8117
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 3.5s finished
```

IHS:

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 3.003935 0.079486 0.816667 0.824224 0.816667
1 3.010830 0.080822 0.840000 0.840415 0.840000
2 2.948162 0.080405 0.790000 0.794553 0.790000
3 2.965462 0.071298 0.773333 0.780449 0.773333
4 3.447498 0.094919 0.823333 0.826367 0.823333
5 3.438412 0.121485 0.790000 0.803212 0.790000

test_f1_macro
0 0.818990
1 0.839940
2 0.790883
3 0.774450
4 0.823950
5 0.793640
Accuracy: 0.8056 | Precision: 0.8115 | Recall: 0.8056 | F1-Score: 0.8070
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 9.8s finished
```

Brovay

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro
0 4.352462 0.073264 0.813333 0.818698 0.813333
1 4.275663 0.077940 0.846667 0.846448 0.846667
2 2.785835 0.073039 0.793333 0.794759 0.793333
3 2.848680 0.083465 0.776667 0.786339 0.776667
4 2.873329 0.072268 0.836667 0.840141 0.836667
5 2.781708 0.067676 0.826667 0.837498 0.826667

test_f1_macro
0 0.814451
1 0.846363
2 0.793118
3 0.779234
4 0.837605
5 0.829338
Accuracy: 0.8156 | Precision: 0.8206 | Recall: 0.8156 | F1-Score: 0.8167
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 10.2s finished
```

### Gram-schmidt

	fit_time	score_time	test_accuracy	test_prec_macro	test_rec_macro
0	3.961153	0.060915	0.780000	0.784933	0.780000
1	4.181968	0.075060	0.820000	0.825977	0.820000
2	2.607430	0.069095	0.760000	0.763097	0.760000
3	2.549828	0.068976	0.756667	0.763454	0.756667
4	2.646971	0.090597	0.800000	0.802131	0.800000
5	2.594054	0.076335	0.776667	0.790321	0.776667

	test_f1_macro
0	0.780573
1	0.821953
2	0.759179
3	0.758541
4	0.798946
5	0.780751

Accuracy: 0.7822 | Precision: 0.7883 | Recall: 0.7822 | F1-Score: 0.7833  
[Parallel(n\_jobs=-1)]: Done 6 out of 6 | elapsed: 9.6s finished

### Lampiran 6. 5-fold XGBoost

Asli:

	fit_time	score_time	test_accuracy	test_prec_macro	test_rec_macro
0	0.316743	0.015836	0.766667	0.769836	0.766667
1	0.314464	0.016818	0.786667	0.790355	0.786667
2	0.308332	0.015175	0.793333	0.793212	0.793333
3	0.328238	0.016297	0.820000	0.822615	0.820000
4	0.301760	0.015481	0.800000	0.800395	0.800000
5	0.297554	0.010097	0.793333	0.804815	0.793333

	test_f1_macro
0	0.767699
1	0.788115
2	0.790506
3	0.821067
4	0.797493
5	0.796163

Accuracy: 0.7933 | Precision: 0.7969 | Recall: 0.7933 | F1-Score: 0.7935  
[Parallel(n\_jobs=-1)]: Done 6 out of 6 | elapsed: 1.0s finished

IHS:

	fit_time	score_time	test_accuracy	test_prec_macro	test_rec_macro
0	2.261993	0.081718	0.806667	0.808623	0.806667
1	2.388983	0.070185	0.836667	0.838853	0.836667
2	1.909832	0.084128	0.793333	0.794358	0.793333
3	1.713064	0.083297	0.773333	0.777450	0.773333
4	1.916356	0.061144	0.813333	0.816839	0.813333
5	1.905273	0.033398	0.813333	0.822935	0.813333

	test_f1_macro
0	0.806051
1	0.836785
2	0.792113
3	0.773864
4	0.812672
5	0.815597

Accuracy: 0.8061 | Precision: 0.8098 | Recall: 0.8061 | F1-Score: 0.8062  
[Parallel(n\_jobs=-1)]: Done 6 out of 6 | elapsed: 10.5s finished

## Brovey

```
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 1.169192 0.045332 0.833333 0.835391 0.833333
1 1.144464 0.038748 0.846667 0.849233 0.846667
2 0.982482 0.019105 0.806667 0.807746 0.806667
3 0.948883 0.016997 0.786667 0.791697 0.786667
4 0.646599 0.017543 0.820000 0.820378 0.820000
5 0.643847 0.016099 0.813333 0.823879 0.813333

test_f1_macro
0 0.833725
1 0.846732
2 0.805273
3 0.787485
4 0.818744
5 0.815937
Accuracy: 0.8178 | Precision: 0.8214 | Recall: 0.8178 | F1-Score: 0.8180
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 2.9s finished
```

## Gram-schmidt

```
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 2 concurrent workers.
fit_time score_time test_accuracy test_prec_macro test_rec_macro \
0 0.838299 0.032394 0.803333 0.808402 0.803333
1 0.833533 0.018796 0.816667 0.819650 0.816667
2 0.602488 0.018976 0.763333 0.765442 0.763333
3 0.605421 0.024331 0.763333 0.771268 0.763333
4 0.580398 0.019205 0.786667 0.788619 0.786667
5 0.576163 0.021464 0.763333 0.774673 0.763333

test_f1_macro
0 0.805017
1 0.817499
2 0.762802
3 0.765152
4 0.785114
5 0.766758
Accuracy: 0.7828 | Precision: 0.7880 | Recall: 0.7828 | F1-Score: 0.7837
[Parallel(n_jobs=-1)]: Done 6 out of 6 | elapsed: 2.1s finished
```

## Lampiran 7. Arsitektur CNN-1D

```
def get_cnn(input_data):
    model = keras.Sequential([
        keras.layers.InputLayer(input_data.shape[1:]),
        keras.layers.Conv1D(filters=32, kernel_size=1,
            activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=32, kernel_size=1,
            activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=64, kernel_size=1,
            activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=64, kernel_size=1,
            activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Flatten(),
        keras.layers.Dense(64, activation="relu"),
        keras.layers.Dense(128, activation="relu"),
        keras.layers.Dropout(0.1),
        keras.layers.Dense(64, activation="relu"),
        keras.layers.Dense(32, activation="relu"),
        keras.layers.Dense(6, activation='softmax')
    ])

    model.compile(
        optimizer='adam',
        loss='categorical_crossentropy',
        metrics=['accuracy', keras.metrics.Precision(name='precision'), keras.metrics.Recall(name='recall')])

    return model
```

## Lampiran 8. 5-fold MLP

Asli:

	accuracy	precision	recall	f1
0	0.794444	0.835913	0.750000	0.790630
1	0.797222	0.839879	0.772222	0.804631
2	0.761111	0.801187	0.750000	0.774749
3	0.811111	0.837838	0.775000	0.805195
4	0.777778	0.813253	0.750000	0.780347

accuracy : 0.7883 precision : 0.8256 ; recall : 0.7594 ; f1-score : 0.7911

IHS:

	accuracy	precision	recall	f1
0	0.805556	0.826979	0.783333	0.804565
1	0.813889	0.832845	0.788889	0.810271
2	0.766667	0.769452	0.741667	0.755304
3	0.819444	0.833811	0.808333	0.820874
4	0.819444	0.829412	0.783333	0.805714

accuracy : 0.8050 precision : 0.8185 ; recall : 0.7811 ; f1-score : 0.7993

Brovey

	accuracy	precision	recall	f1
0	0.775000	0.794643	0.741667	0.767241
1	0.788889	0.806548	0.752778	0.778736
2	0.738889	0.746398	0.719444	0.732673
3	0.811111	0.827988	0.788889	0.807966
4	0.802778	0.832845	0.788889	0.810271

accuracy : 0.7833 precision : 0.8017 ; recall : 0.7583 ; f1-score : 0.7794

### Gram-schmidt

	accuracy	precision	recall	f1
0	0.760000	0.776173	0.716667	0.745234
1	0.816667	0.832740	0.780000	0.805508
2	0.763333	0.785455	0.720000	0.751304
3	0.760000	0.790780	0.743333	0.766323
4	0.793333	0.835125	0.776667	0.804836
5	0.806667	0.830986	0.786667	0.808219

accuracy : 0.7833 precision : 0.8085 ; recall : 0.7539 ; f1-score : 0.7802

### Lampiran 9. 5-fold CNN-1D

Asli:

	accuracy	precision	recall	f1
0	0.760000	0.776173	0.716667	0.745234
1	0.816667	0.832740	0.780000	0.805508
2	0.763333	0.785455	0.720000	0.751304
3	0.760000	0.790780	0.743333	0.766323
4	0.793333	0.835125	0.776667	0.804836
5	0.806667	0.830986	0.786667	0.808219

accuracy : 0.7833 precision : 0.8085 ; recall : 0.7539 ; f1-score : 0.7802

IHS:

	accuracy	precision	recall	f1
0	0.775000	0.797688	0.766667	0.781870
1	0.819444	0.823864	0.805556	0.814607
2	0.716667	0.719888	0.713889	0.716876
3	0.825000	0.831909	0.811111	0.821378
4	0.808333	0.810198	0.794444	0.802244

accuracy : 0.7889 precision : 0.7967 ; recall : 0.7783 ; f1-score : 0.7874

### *Brovey*

	accuracy	precision	recall	f1
0	0.769444	0.799392	0.730556	0.763425
1	0.788889	0.805233	0.769444	0.786932
2	0.741667	0.745714	0.725000	0.735211
3	0.808333	0.814286	0.791667	0.802817
4	0.791667	0.806452	0.763889	0.784593

accuracy : 0.7800 precision : 0.7942 ; recall : 0.7561 ; f1-score : 0.7746


### *Gram-Schmidt*

	accuracy	precision	recall	f1
0	0.736667	0.766423	0.700000	0.731707
1	0.823333	0.832168	0.793333	0.812287
2	0.730000	0.751748	0.716667	0.733788
3	0.773333	0.789655	0.763333	0.776271
4	0.813333	0.837370	0.806667	0.821732
5	0.746667	0.760417	0.730000	0.744898


accuracy : 0.7706 precision : 0.7896 ; recall : 0.7517 ; f1-score : 0.7701

## Lampiran 10. Peta estimasi luas lahan perkebunan kopi

Kecamatan Mekakau Ilir :



Kecamatan Banding Agung :







Kecamatan  
Selatan

Warkuk


Ranau

Kecamatan BPR Ranau Tengah





Kecamatan Buay Pemaca

Kecamatan Simpang




Kecamatan Buana Pemaca


Kecamatan Buay Rawan




Kecamatan Buay Sandang Aji




Kecamatan Tiga Dihaji




Kecamatan Buay Runjung




Kecamatan Runjung Agung



Kecamatan Kisam Tinggi




Kecamatan Muaradua Kisam







Kecamatan Kisam Ilir




Kecamatan Pulau Beringin



Kecamatan Sindang Danau



Kecamatan Sungai Are



## **RIWAYAT HIDUP**

Penulis bernama Anasrul, lahir di Koto Laweh pada tanggal 05 Agustus 2002. Penulis merupakan anak laki-laki dari pasangan Bapak Jon Efendian dan Ibu Elfita dan merupakan anak kedua dari empat bersaudara. Penulis tinggal di Kabupaten Tanah Datar hingga saat ini.

Penulis mulai mengenyam pendidikan pendidikan dasar di Min Puncak Alai mulai tahun 2008 hingga lulus tahun 2014. Pada tahun 2017, penulis menyelesaikan pendidikan menengah pertama di MTsN Lawang Mandahiliang dan selanjutnya melanjutkan sekolah di SMA Negeri 1 Sumatera Barat pada tahun 2017. Pada tahun 2020, penulis diterima untuk mengikuti pendidikan di Politeknik Statistika STIS.

Akhirnya pada tahun 2024, atas izin Allah SWT, dukungan dan do'a dari keluarga dan teman, penulis berhasil menyelesaikan pendidikan Program Diploma IV di Politeknik Statistika STIS pada Jurusan Komputasi Statistik peminatan Sains Data.