

Analisis *Pan-Sharpening* untuk Peningkatan Akurasi Deteksi dan Estimasi Luas Lahan Perkebunan Kopi

(Studi Kasus : Kabupaten OKU Selatan, Provinsi Sumatera Selatan)

Anasrul¹
Rani Nooraeni²

Penggunaan teknologi *remote sensing* dalam pemantauan perkebunan kopi menjadi semakin penting mengingat peran vital kopi dalam perekonomian sebagai produk ekspor yang meningkatkan pendapatan negara. Indonesia, sebagai produsen kopi terbesar ketiga di dunia. Namun, data luas areal perkebunan kopi hanya tersedia dari Survei Perusahaan Perkebunan (SKB) yang memiliki keterbatasan. Pada prosesnya, diperlukan banyak tenaga atau petugas cacah sehingga membutuhkan biaya pelaksanaan yang besar. Oleh karena itu, dibutuhkan alternatif lain seperti *remote sensing*. Meskipun demikian, tantangan masih ada, terutama terkait resolusi citra satelit yang rendah yang menghambat pemantauan akurat dan efisien terhadap lahan kopi. Penelitian ini bertujuan untuk meningkatkan akurasi analisis lahan perkebunan kopi di Kabupaten OKU Selatan, Provinsi Sumatera Selatan, dengan penggunaan metode *pan-sharpening* yang terdiri dari IHS, *Brovey*, dan *Gram-Schmidt* serta dibantu dengan indeks komposit. Pengambilan data sampel citra satelit dari Landsat-8 dilakukan pada 1800 titik yang terbagi menjadi enam kelas. Pada hasil penelitian terlihat penciri lahan perkebunan kopi memiliki nilai NDVI, EVI, dan ARVI yang cenderung lebih rendah akan tetapi pada nilai NDBI dan NDWI memiliki nilai yang cenderung lebih tinggi dari kelas perkebunan non-kopi dan hutan. Penelitian ini juga membandingkan data hasil metode *pan-sharpening* dengan menggunakan metode *machine learning* dan *deep learning* untuk mendapatkan model pengklasifikasian terbaik. Hasil penelitian menunjukkan metode *machine learning* model SVM pada data hasil *pan-sharpening* *brovey* memberikan hasil terbaik dengan nilai AKURASI SEBESAR 83,49 dan F1-score sebesar 83,59 persen.

Kata Kunci— Perkebunan Kopi, *pan-sharpening*, *machine learning*, *deep learning*, *remote sensing*.

I. LATAR BELAKANG

Kopi merupakan komoditas ekspor yang mempunyai nilai ekonomis yang relatif tinggi di pasaran dunia. Kopi sendiri merupakan salah satu komoditas pangan yang paling banyak diperdagangkan di dunia. Menurut *Statista Research Department*, pasar global untuk kedai kopi diperkirakan mencapai \$165,7 miliar pada tahun 2022 (*Coffee Shops - Global Strategic Business Report*, 2021). Selain itu, kopi juga merupakan salah satu komoditas terpenting dalam perdagangan internasional dan memiliki peran signifikan dalam mempengaruhi perekonomian global. Indonesia menjadi salah satu negara pengekspor utama komoditi kopi dunia. Tahun

2022, Indonesia menjadi negara pengekspor kopi urutan ketiga setelah Brazil dan Vietnam. Indonesia tercatat memproduksi kopi sebanyak 11,85 juta kantong. Sementara Brazil memproduksi kopi sebanyak 62,6 juta kantong kopi. kemudian, Vietnam yang memproduksi kopi 29,75 juta kantong kopi (*Coffee: World Markets and Trade*, 2021).

Provinsi Sumatera menjadi penyumbang terbesar produksi kopi di Indonesia pada tahun 2022, menyumbang sekitar 26,72 persen dari total produksi nasional, dengan jumlah produksi mencapai 212,4 ribu ton. Produksi kopi di Sumatera Selatan mengalami peningkatan sebesar 0,33 persen dari tahun sebelumnya (Nurhanisah, 2023). Tingkat produksi kopi sangat tergantung pada luas lahan perkebunan, yang dapat dihitung berdasarkan luasnya. Luas lahan perkebunan kopi di Sumatera Selatan pada tahun 2022 mencapai 267.867 hektar. Kabupaten OKU Selatan merupakan kabupaten dengan luas lahan perkebunan kopi terbesar di Provinsi Sumatera Selatan, mencapai 89.823,5 hektar atau sekitar 33,2 persen dari total luas perkebunan kopi di provinsi tersebut. Namun, terjadi penurunan luas lahan perkebunan kopi sebesar 0,63 persen di Kabupaten OKU Selatan sejak tahun 2021.

Pengumpulan data mengenai lahan perkebunan kopi adalah sebuah proses yang krusial untuk memastikan keakuratan dan ketepatan informasi yang diperoleh. Saat ini, di Indonesia, pendekatan konvensional digunakan untuk menghimpun data mengenai perkebunan kopi. Identifikasi lahan perkebunan kopi dilakukan melalui Survei Perusahaan Perkebunan (SKB) yang dilaksanakan oleh Badan Pusat Statistik (BPS). Metode yang digunakan meliputi pencacahan lengkap mandiri atau *self-enumeration*, serta analisis perkebunan melalui Sistem Elektronik Akurat Akuntabel dan Aman (SEAAP) oleh pemilik perkebunan, juga pengisian data melalui platform SKB online bagi yang belum melakukan pencacahan mandiri. Selain itu, data juga diperoleh dari Direktorat Jenderal Perkebunan, Kementerian Pertanian. Informasi yang terkumpul mengenai lahan perkebunan kopi mencakup luas lahan, jumlah produksi, produktivitas, status tanaman, dan status perusahaan (Direktorat STPHP, 2022). Dalam konteks Survei Perusahaan Perkebunan (SKB) yang dilakukan oleh BPS, data dikumpulkan untuk perkebunan dengan status perusahaan Perkebunan Besar Negara (PBN) dan Perkebunan Besar Swasta (PBS). Sementara itu, Direktorat Jenderal Perkebunan mengumpulkan data mengenai Perkebunan Rakyat (PR)

Pendekatan konvensional yang saat ini digunakan memiliki beberapa kelemahan yang signifikan. Salah satunya adalah waktu yang dibutuhkan untuk melaksanakan survei, yang seringkali mengakibatkan keterlambatan dalam penyediaan

data hingga setahun lamanya. Selain itu, pendekatan ini memerlukan jumlah tenaga kerja yang cukup besar dan biaya yang signifikan, terutama di wilayah perkebunan yang luas atau sulit dijangkau. Kelemahan-kelemahan ini mendorong upaya untuk mencari alternatif yang lebih efisien dalam pengumpulan data lahan perkebunan kopi. Salah satu alternatif yang menjanjikan adalah memanfaatkan teknologi *remote sensing* atau penginderaan jauh. Tantangan utama teknologi ini dimana resolusi citra satelit yang masih relatif rendah. Resolusi rendah dapat menghambat kemampuan untuk melakukan pemantauan yang akurat dan efisien sehingga dibutuhkan metode *pan-sharpening* untuk meningkatkan resolusi tersebut. Teknologi ini dapat memberikan solusi untuk meningkatkan kualitas pengumpulan data tanpa mengorbankan waktu dan sumber daya yang signifikan.

Penelitian (Aziz, 2019) sebelumnya telah membahas penggunaan penginderaan jauh dan citra satelit untuk mengestimasi dan menguji ketelitian hasil estimasi produksi tanaman kopi. Penelitian ini juga telah menganalisis berbagai indeks vegetasi dan data satelit untuk mengidentifikasi lahan perkebunan kopi. Namun, pada penelitian ini hanya berfokus penggunaan satu indeks vegetasi dan tidak ada penggabungan beberapa indeks vegetasi untuk menganalisis lahan kopi. Sementara itu, penelitian (Damayanti and Liyantono, 2021) telah membahas penggunaan algoritma *machine learning* untuk mengidentifikasi dan memetakan lahan perkebunan kopi. Penelitian ini dilakukan dengan menggunakan teknologi SVM dan *Random Forest* untuk memproses citra satelit Landsat-8 dan mengidentifikasi lahan perkebunan kopi.

Perkembangan teknologi penginderaan jauh satelit saat ini mengarah pada peningkatan resolusi spasial (high resolution) dan peningkatan saluran spektral (hyperspectral). Satelit Landsat-8 OLI memiliki saluran multispektral dan saluran pankromatik dengan resolusi spasial yang lebih baik. Penelitian (Dibs et al., 2021) memanfaatkan perkembangan ini untuk mengestimasi tutupan lahan (LULC). Saluran multispektral memberikan informasi warna, sedangkan saluran pankromatik memberikan informasi tekstur yang lebih menonjol. Dengan menggabungkan kedua informasi tersebut, diharapkan mampu memberikan informasi yang lebih detail dan akurat mengenai suatu obyek.

Oleh karena itu, penelitian ini diarahkan pada perkembangan teknologi penginderaan jauh dengan memberikan beberapa metode untuk melakukan penggabungan citra yang biasa disebut dengan *pan-sharpening* dan memanfaatkan indeks vegetasi dalam membedakan lahan perkebunan kopi. Metode-metode *pan-sharpening* tersebut menghasilkan citra dengan nilai spektral yang berbeda-beda, sesuai dengan algoritmanya. Dalam penelitian kali ini akan menganalisis beberapa metode *pan-sharpening* tersebut. Untuk melihat metode manakah yang memiliki akurasi lebih baik, metode-metode tersebut akan dibandingkan dengan cara melakukan uji akurasi antara hasil klasifikasi citra terhadap data sebenarnya di lapangan. Penggunaan citra satelit Landsat-8 OLI perlu dikaji kembali. Penelitian ini diarahkan pada kajian penggunaan data Landsat-8 OLI pada lahan kopi, khususnya yang berhubungan dengan peningkatan akurasi dan estimasi luas perkebunan kopi.

II. TUJUAN PENELITIAN

Tujuan penelitian yang akan dilakukan adalah:

1. Mengetahui efek dari berbagai metode *pan-sharpening* untuk mendeteksi lahan perkebunan kopi
2. Membentuk model klasifikasi terbaik dalam mendeteksi lahan perkebunan kopi
3. Menganalisis tingkat ketelitian metode *pan-sharpening* dan mengestimasi luas lahan perkebunan kopi menggunakan model terbaik yang didapat.

III. PENELITIAN TERKAIT

Teknologi *remote sensing* menjadi alternatif penting dalam menganalisis lahan perkebunan kopi. Penelitian (Jagannathan and Divya, 2020) bertujuan untuk memprediksi dan mengklasifikasikan perubahan penggunaan lahan dan tutupan lahan menggunakan jaringan saraf konvolusi dalam pembelajaran mendalam metode *Convolutional Neural Network* (CNN) pada citra satelit Sentinel-2. Penelitian ini dilakukan dengan menggunakan teknologi jaringan saraf konvolusi (CNN) untuk memproses citra satelit Sentinel-2 dan memprediksi perubahan penggunaan lahan dan tutupan lahan. Hasil penelitian menunjukkan bahwa teknologi CNN dapat digunakan untuk memprediksi perubahan penggunaan lahan dan tutupan lahan dengan akurasi yang tinggi¹.


Penelitian (Dibs et al., 2021) menemukan metode penyempurnaan estimasi penggunaan dan tutupan lahan (LULC) dengan menggunakan citra jarak jauh menggunakan tiga pendekatan *pan-sharpening* untuk menggabungkan citra pankromatik dengan resolusi spasial tinggi dengan citra multispektral dengan resolusi spasial rendah pada citra satelit Landsat-8 OLI. Penelitian ini bertujuan untuk meningkatkan akurasi estimasi penggunaan dan tutupan lahan (LULC) dengan menggunakan teknologi *pan-sharpening* pada citra satelit Landsat-8 OLI. Hasil penelitian menunjukkan bahwa teknologi *pan-sharpening* dapat meningkatkan akurasi estimasi penggunaan dan tutupan lahan (LULC) pada citra satelit Landsat-8 OLI.

Penelitian (Damayanti and Liyantono, 2021) bertujuan untuk mengidentifikasi dan memetakan lahan perkebunan kopi dengan memanfaatkan citra satelit Landsat-8 pada platform *Google Earth Engine* (GEE) menggunakan model *Support vector machine* (SVM) dan *Random Forest*. Penelitian ini dilakukan dengan menggunakan teknologi SVM dan *Random Forest* untuk memproses citra satelit Landsat-8 dan mengidentifikasi lahan perkebunan kopi. Hasil penelitian menunjukkan bahwa teknologi SVM dan *Random Forest* dapat digunakan untuk mengidentifikasi dan memetakan lahan perkebunan kopi dengan akurasi yang tinggi.

IV. METODE PENELITIAN

4.1 Wilayah Studi

Provinsi Sumatera Selatan merupakan provinsi penghasil produksi kopi terbesar di Indonesia. Berdasarkan data BPS, pada tahun 2022 tercatat produksi kopi sebesar 201.400 ton atau 26,72 persen dari total produksi kopi nasional. Kabupaten OKU Selatan memiliki luas



Gambar 1. Citra Landsat-8 Kabupaten Oku Selatan

4.2 Pengumpulan Data

Data Citra Landsat-8

Data yang digunakan adalah citra satelit Landsat 8 *Collection 2 Tier 1 TOA Reflectance* yang memiliki resolusi spasial hingga 30 meter dengan resolusi temporal 16 hari (Yusof, Shafri, and Shaharum, 2021). Citra Landsat-8 yang diunduh yaitu data citra yang berada dalam rentang 1 Januari sampai 31 Desember tahun 2022. Data dikumpulkan melalui platform Google Earth Engine. Sebelum digunakan untuk analisis, citra satelit melalui proses *cloud masking* untuk menghilangkan awan dan digabungkan menggunakan *reducer median*.

Data Sampel

Pengambilan titik sampel dibagi menjadi enam kelas target yang terdiri dari kelas air, perkebunan kopi, perkebunan non-kopi, hutan, bangunan, dan tanah. Sebanyak 1.800 sampel diambil dan setiap kelasnya memiliki ukuran yang sama yaitu 300 sampel yang mana setiap sampel berupa grid dengan ukuran 10×10 meter. Hal bertujuan untuk menghindari data *imbalance*, yaitu kondisi salah satu kelas target atau lebih yang ada terdapat suatu himpunan memiliki jumlah yang cukup timpang. Langkah pertama melakukan *geotagging* objek yang diamati. Kemudian didapatkan piksel hasil *geotagging* yang mewakili satu titik sampel dan satu kelas target.

Dalam penentuan minimum jumlah sampel tiap kelas, menganut *rule of thumb* (Haub et al., 2015). Pada penelitian ini, jumlah kelas yang digunakan sebanyak enam kelas dan luas lokasi uji lebih dari lima ratus ribu hektar, sehingga memerlukan setidaknya pada tiap kelas 75 sampai 100 sampel (Haub et al., 2015). Oleh karena itu, titik sampel yang didapatkan sudah memenuhi syarat minimum pengambilan sampel tiap kelas.

Pemberian label

Pelabelan dibantu menggunakan alat bantu citra satelit milik *Google Earth*, informasi lokasi sampel dari *Google Earth Engine* (GEE), tangkapan kamera *Google Street*

perkebunan kopi terluas jika dibandingkan dengan kabupaten dan kota lainnya di Provinsi Sumatera Selatan, yaitu sebesar 89.823,5 hektar (Ha) (BPS, 2021-2022). Oleh karena itu, kabupaten OKU Selatan dipilih sebagai Region of Interest (ROI) atau studi lokasi.

View, informasi perkebunan yang terdaftar di *Google Maps* dan data pendukung Geoportal Kabupaten OKU Selatan. Hal ini disebabkan karena belum tersedianya publikasi data administratif resmi perkebunan kopi secara khusus pada setiap titik-titik koordinat di Indonesia. Perlu diketahui bahwa proses pengambilan titik sampel merupakan tahapan dengan tingkat kesulitan yang paling tinggi, mengingat lumayan sulit membedakan citra kelas perkebunan kopi dengan kelas hutan. Proses validasi dilakukan dengan mengambil informasi koordinat longitude dan latitude dari titik sample. Kemudian menggunakan *Google Earth* untuk menuju lokasi dan dipastikan kembali dengan *Google Street View*.



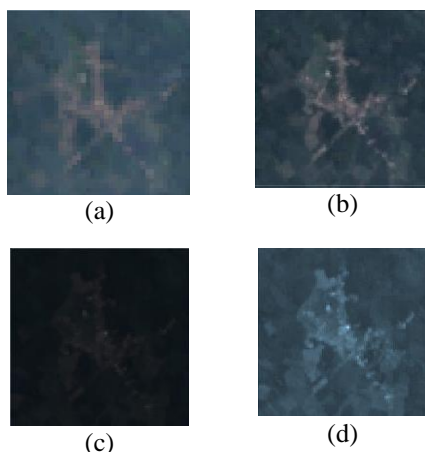
Gambar 2. Citra Perkebunan Kopi (-4.78,103.92) :
(a) Google Street View; (b) Google Earth

Proses Pan-sharpening

Pan-sharpening dilakukan untuk meningkatkan dan mempertajam resolusi spasial citra guna memperoleh informasi yang lebih banyak daripada citra yang tidak terfusi. Hal ini sangat diperlukan untuk meningkatkan resolusi spasial dari band-band multispektral maupun hyperspektral menjadi resolusi spasial pada band pankromatik. Penajaman citra pada umumnya hanya digunakan untuk tujuan meningkatkan kualitas visual citra karena keterbatasan lebar band pankromatik, yang menyebabkan band-band di luar panjang gelombang tampak secara teori memiliki nilai spektral yang tidak sesuai lagi dengan nilai aslinya. Dalam penelitian ini, tiga metode *pan-sharpening* yang digunakan adalah IHS (*Intensity-Hue-Saturation*), *Brovey*, dan *Gram-Schmidt*, yang masing-masing dipilih karena alasan spesifik. Metode IHS dipilih karena kemampuannya menggabungkan informasi warna dari citra multispektral dengan detail spasial dari citra pankromatik, serta mempertahankan kualitas warna yang baik, cocok untuk analisis vegetasi dan pemetaan lahan (Carper, Lillesand, and Kiefer, 1990). Metode *Brovey* dipilih karena kesederhanaannya dan kemampuannya dalam mempertajam citra tanpa menghilangkan informasi spektral, sering digunakan dalam pemetaan geologi dan identifikasi fitur urban (Chavez, Sides, and Anderson, 1991). Metode *Gram-Schmidt* dipilih

karena transformasi matematisnya yang efektif dalam meningkatkan resolusi spasial tanpa mengorbankan informasi spektral, sangat berguna dalam studi perubahan lingkungan dan pemantauan wilayah (Chavez, Sides, and Anderson, 1991). Ketiga metode ini dipilih karena keunggulannya dalam mempertahankan integritas spektral dan meningkatkan kualitas visual citra hasil pan-sharpening. Metode *Intensity Hue Saturation* (IHS) memecah warna menjadi *intensity* (I), *hue* (H), dan *saturation* (S), yang sesuai dengan pemahaman manusia terhadap warna (Sitanggang, Carolita, and Trisasongko, 2004). Metode *Brovey Transformation* (BT) menggabungkan citra dengan resolusi berbeda, meningkatkan kontras dan kecerahan citra untuk memberikan hasil yang lebih tajam dan detail (Wandayani, 2007). Sementara Metode *Gram-Schmidt*, atau modulasi intensitas berbasis filter penghalusan (SFIM), melibatkan simulasi dan transformasi untuk meningkatkan ketajaman citra, menghasilkan citra yang lebih jelas dan detail, sesuai dengan kebutuhan analisis yang lebih mendalam (Daenodoro, 2012).

Untuk mengamati kenampakan visual hasil dari pan-sharpening, penelitian ini mengambil beberapa sampel untuk perbedaan kenampakan visual antara citra landsat-8, pan-sharpening metode IHS, *Brovey*, dan *Gram-Schmidt*.



Gambar 3. Penampakan Visual: (a) Asli; (b) IHS; (c) *Brovey*; (d) *Gram-schmidt*

Secara visual, citra hasil *Brovey* memiliki ketajaman spasial yang tinggi, tetapi informasi warnanya berbeda dari citra multispektral awal karena metode *Brovey* hanya menggunakan rasio dari 3 band spektral. Di sisi lain, metode *Gram Schmidt* menghasilkan gambar yang lebih jelas dan tajam, meskipun warna hijau sedikit menurun. Pada metode HIS gambar dihasilkan hampir menyerupai warna aslinya tapi ketajaman spasial tidak sebaik metode *brovey*. Pemilihan metode yang cocok harus disesuaikan dengan tujuan analisis citra, seperti pengamatan spektral atau pengamatan tepian objek.

Pengumpulan Fitur

Koleksi fitur terdiri dari beberapa pita multispektral dan indeks komposit sebagai variabel prediktor. Pita

multispektral adalah spektrum atau gelombang elektromagnetik dipancarkan dari citra satelit dengan panjang gelombang tertentu. Hanya tiga gelombang elektromagnetik yang dapat dilihat oleh mata manusia, yaitu merah (*red*), hijau (*green*), dan biru (*blue*) atau RGB. Sementara itu, gelombang lainnya tidak dapat dilihat dengan mata manusia, misalnya *Near-Infrared* (NIR) dan *Short Wave Infrared* (SWIR). Objek amatan akan menyerap spektrum dan nilai masing-masing gelombang akan diproses dan dihitung. Tabel II menunjukkan pita multispektral yang digunakan pada penelitian ini.

TABEL I
PITA MULTISPEKTRAL CITRA SATELIT

<i>Landsat-8</i>	<i>Bands</i>	<i>Wavelength (micrometer)</i>	<i>Resolusi</i>
<i>Blue</i>	B2	0.45 – 0.51	30 m
<i>Green</i>	B3	0.53 – 0.59	30 m
<i>Red</i>	B4	0.64 – 0.67	30 m
<i>NIR</i>	B5	0.85 – 0.88	30 m
<i>SWIR 1</i>	B6	1.57 – 1.65	30 m
<i>SWIR 2</i>	B7	2.11 – 2.29	30 m

Sumber: USGS (Sitanggang, Carolita, and Trisasongko, 2004)

Indeks komposit dihasilkan melalui transformasi beberapa pita spektral. Biasanya, indeks komposit digunakan untuk tugas tertentu (USGS, 2022). Indeks vegetasi yang digunakan untuk membedakan kelas perkebunan kopi, perkebunan nonkopi, dan hutan, yaitu *Normalized Difference Vegetation Index* (NDVI), *Atmospherically Resistant Vegetation Index* (ARVI), dan *Enhanced Vegetation Index* (EVI) (Hoeser, Bachofer, and Kuenzer, 2020). NDVI merupakan indeks vegetasi yang menggambarkan tingkat kehijauan suatu tanaman yang berasal dari kombinasi matematis antara band merah dan band NIR yang digunakan sebagai indikator keberadaan dan kondisi vegetasi (Bezerra et al., 2020). ARVI merupakan indeks alternatif untuk mengurangi ketergantungan dengan NDVI yang memanfaatkan informasi atmosfer yang terkandung dalam band biru (Lillesand, Kiefer, and Chipman, 2015). EVI-2 merupakan alternatif dari EVI tanpa pita biru, yang memiliki konsistensi yang sama di berbagai jenis tutupan lahan dan tidak bergantung pada tutupan lahan serta dikembangkan untuk mengoptimalkan sinyal vegetasi melalui pengaruh dari latar belakang tanah dan sinyal kanopi (Rondeaux, Steven, and Baret, 1996). *Normal Difference Built-up Index* (NDBI) sensitif terhadap lahan bangunan atau lahan terbuka (Jiang et al., 2008). Sementara itu, untuk daerah genangan air menggunakan *Normalized Difference Water Index* (NDWI) (Hidayati, Suharyadi, and Danoedoro, 2018). Berikut Tabel III adalah formula dari indeks komposit NDVI, ARVI, EVI-2, NDBI, dan NDWI.

TABEL II
FORMULA INDEKS KOMPOSIT

<i>Indeks Komposit</i>	<i>Persamaan Band yang digunakan^a</i>
------------------------	--

NDVI	$(NIR - Red)/(NIR + Red)$
ARVI	$(NIR - \gamma * Red - Blue)/(NIR + \gamma * Red - Blue)$
EVI-2	$2.5 * (NIR - Red)/(NIR + 2.4 * Red + 1)$
NDBI	$(SWIR1 - NIR)/(SWIR1 + NIR)$
NDWI	$(Green - NIR)/(Green + NIR)$

4.3 Metode Analisis

Analisis deskriptif dilakukan untuk mengetahui efek dari berbagai metode penajaman untuk mendeteksi lahan perkebunan kopi menggunakan data pita multispektral, saluran pakromatik dan indeks komposit. Penajaman citra digunakan secara otomatis untuk menggabungkan (fusi) suatu citra warna, multispektral, atau hyperspektral yang mempunyai resolusi spasial rendah dengan suatu citra tingkat keabuan yang mempunyai resolusi spasial tinggi dengan melakukan resampling terhadap ukuran elemen citra (pixel resolusi spasial tinggi tersebut. Penajaman citra dengan menggunakan data citra pankromatik (*image Pan-sharpening*) adalah dengan menggabungkan data citra multispektral (warna) yang mempunyai resolusi rendah dengan citra pankromatik (hitam-putih atau tingkat keabuan) yang mempunyai resolusi tinggi Indeks komposit yang digunakan, yaitu NDVI, ARVI, EVI-2, NDBI, dan NDWI. Data array dikelompokkan pada rentang tertentu dengan jenks natural breaks. Jenks natural breaks merupakan jenis metode klasifikasi optimal yang bertujuan untuk memaksimalkan varians antarkelas dan meminimalkan varians dalam kelas. Pengelompokan data antarkelas berdasarkan informasi yang melekat dalam data (*data-driven*). Rentang level dibagi menjadi lima, yaitu *very low*, *low*, *medium*, *high*, dan *very high* (Gautam et al., 2015). Pengujian *Goodness of Variance Fit* (GVF) yang menghasilkan nilai mendekati satu menunjukkan pada variasi antarkelas yang dibagi optimum.

Untuk tujuan pengidentifikasian model klasifikasi terbaik penciri lahan perkebunan kopi, dilakukan proses modelling dengan mengimplementasikan algoritma supervised classification pada machine learning dan deep learning. Pada *machine learning*, digunakan algoritma klasifikasi, yaitu *Support Vector Machines* (SVM), *random forest*, dan *Extreme Gradient Boosting* (XGBoost). Sementara itu, pada *deep learning* menggunakan *Multi-Layer Perceptron* (MLP) dan *Convolutional Neural Network* (CNN-1D). Pada *machine learning* dilakukan *hyperparameter tuning* menggunakan *grid search*. Kemudian dilakukan evaluasi model menggunakan *stratified 5-fold cross validation* untuk menghindari efek kebetulan dan menghindari kemungkinan *overfitting* agar lebih yakin dalam pemilihan model terbaik.

a. Machine Learning

SVM merupakan metode *machine learning* yang digunakan untuk data berdimensi tinggi untuk menemukan sebuah batasan yang optimal dalam memisahkan kelas yang satu dengan yang lain. Algoritma ini tidak mudah terjadi *overfitting* dan dapat menghasilkan akurasi tinggi pada

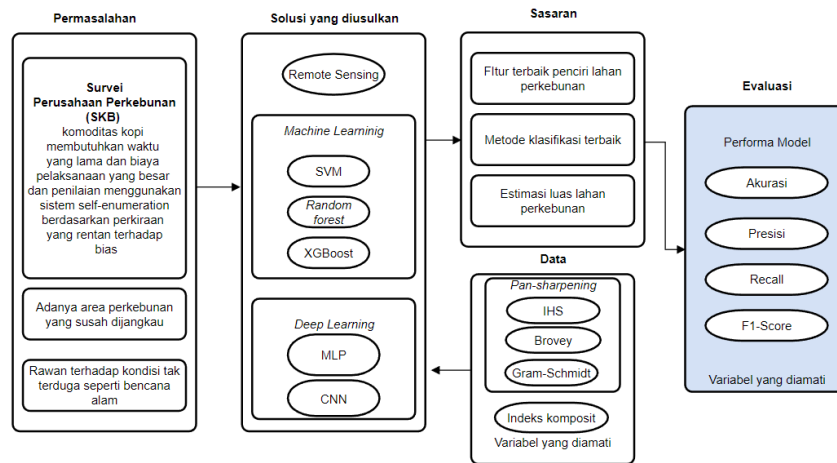
model *nonlinear* yang kompleks (Verde et al., 2020). *Random forest* merupakan algoritma untuk mengklasifikasikan data yang didasarkan pada pohon keputusan. *Random forest* adalah kombinasi dari beberapa pohon keputusan di mana setiap pohon bergantung pada nilai vektor acak yang sampelnya diambil secara independen dan dengan distribusi yang sama untuk semua pohon di *random forest*. Metode *random forest* merupakan metode klasifikasi yang efektif (Chen, Dou, and Yang, 2017). Kelebihan dari metode ini dapat memproses data dalam jumlah besar, dengan variabel yang banyak, dan sensitif terhadap multikolinieritas maupun *overfitting* (Breiman, 2001). XGBoost merupakan algoritma *tree-based ensemble learning* yang terdiri dari pohon keputusan (*decision tree*). Pohon keputusan dibangun secara urut untuk mengurangi kesalahan residual dari pohon keputusan sebelumnya. Pengklasifikasi dasar adalah pengklasifikasi lemah yang cocok dengan data. Setiap pengklasifikasi baru mempertimbangkan pengklasifikasi sebelumnya sehingga menghasilkan performa yang lebih baik (Triscowati et al., 2019). Dari sudut pandang komputasi, algoritma XGBoost lebih cepat daripada implementasi *gradient boosting* lainnya serta mampu bekerja dengan baik bahkan dengan banyak missing value (Budholiya, Shrivastava, and Sharma, 2020).

b. Deep Learning

MLP merupakan model *neural network* yang terdiri dari beberapa *hidden layer* dan *node* antar *layer* saling terhubung satu sama lain. Arsitektur MLP terdiri dari input *layer*, satu atau lebih *hidden layer*, dan output *layer*. *Layer input* menerima sinyal dari luar, kemudian melewatkannya ke *hidden layer* pertama yang akan diteruskan sehingga akhirnya mencapai output *layer* (Putra and Azhar, 2021). CNN merupakan operasi konvolusi penggabungan beberapa lapisan pemrosesan dan menggunakan elemen dalam beroperasi secara paralel yang terinspirasi dari sistem saraf biologis. Arsitektur CNN 1-D terdiri dari 3 bagian *layer*, yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer* (Jiang et al., 2018). *Pooling layer* beserta *dropout* mampu untuk meningkatkan performa model dan mengurangi *overfitting* (Hu et al., 2015).

V. KERANGKA PIKIR

Penelitian ini diawali dengan adanya keterbatasan pada metode pengumpulan data pada Survei Perusahaan Perkebunan (SKB) komoditas k oleh Badan Pusat Statistik yang membutuhkan banyak tenaga, waktu, dan biaya yang besar serta sulitnya mencapai area perkebunan kopi. Kerangka pikir menggambarkan jalannya penelitian mulai dari permasalahan, solusi yang diusulkan, sasaran penelitian, dan indikator evaluasi. Kerangka pikir pada penelitian ini mengacu pada (Peryanto, Yudhana, and Umar, 2020) dan diilustrasikan pada gambar 3.




Gambar 3. Kerangka pikir



VI. HASIL DAN PEMBAHASAN

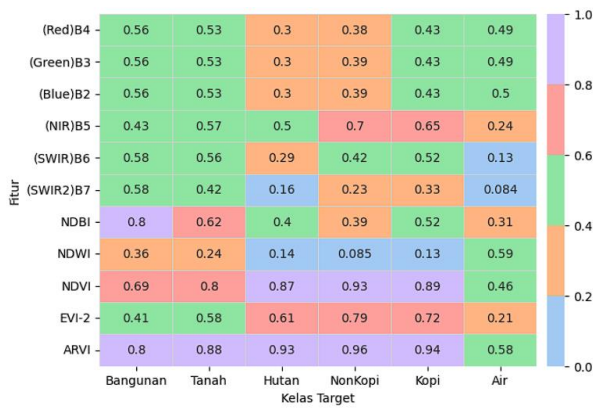
A. Identifikasi Fitur Terbaik Penciri Perkebunan Kopi

Untuk menganalisis efek dari berbagai metode *pan-sharpening*, analisis deskriptif digunakan untuk mengidentifikasi fitur pada citra satelit Landsat-8. Pita multispektral digunakan untuk membentuk indeks komposit, dan seluruh pita multispektral serta indeks komposit Landsat-8 dinormalisasi dan distandardisasi. Setelah itu, perhitungan GVF dilakukan untuk setiap fitur sebelum dibagi menjadi lima level menggunakan metode *jenks natural breaks*. Hasil menunjukkan bahwa nilai perhitungan GVF mendekati satu, yang mengindikasikan bahwa fitur dapat dikelompokkan menurut levelnya. Distribusi fitur untuk setiap kelas ditunjukkan dengan heatmap pada gambar 4, gambar 5, gambar 6 dan gambar 7.



Gambar 4. Distribusi nilai GVF berdasarkan fiturnya pada citra asli

Gambar 5. Distribusi fitur pada *Pan-sharpening* IHSGambar 6. Distribusi fitur pada *Pan-sharpening* Brovey



Gambar 7. Distribusi fitur pada Pan-sharpening Gram-Schmidt

Berdasarkan gambar 4, gambar 5, gambar 6 dan gambar 7, diperoleh informasi mengenai perbedaan nilai band pada tiap-tiap kelas. Nilai rata-rata pita multispektral atau band bawaan (RGB, NIR, SWIR 1, dan SWIR 2) dari *pan-sharpening* IHS, *Brovey*, ataupun *Gram-schmidt* hampir tidak ada perbedaan antarkelas atau serupa, sehingga sulit untuk membedakan kelas-kelas lainnya. Oleh karena itu, indeks komposit yang merupakan kombinasi dari beberapa band yang ada cukup dapat membantu untuk membedakan kelas tutupan lahan. Penciri lahan perkebunan kopi didapatkan nilai yang mirip, baik IHS, *Brovey*, maupun *Gram-schmidt*, yaitu pada fitur NDWI berada pada level very low; fitur SWIR 2 berada pada level low; SWIR2 berada pada level *medium*; EVI-2 berada pada level *high* dan indeks vegetasi NDVI, dan ARVI berada pada level *very high*, namun pada fitur RGB (red, green, dan blue) berada pada level yang cukup beragam untuk citra asli, *pan-sharpening* IHS, *Brovey*, ataupun *Gram-schmidt*.

Secara lebih rinci, NDBI mudah untuk membedakan kelas bangunan dan tanah dengan kelas lainnya, ditandai dengan perolehan nilai *mean* yang tinggi dari pada kelas lain dan kelas bangunan mempunyai nilai lebih tinggi daripada kelas tanah. NDWI juga mampu untuk membedakan kelas air dengan kelas lainnya. Sementara itu, pada indeks vegetasi (NDVI, EVI-2, dan ARVI) belum bisa membedakan kelas perkebunan kopi, perkebunan non-kopi, dan hutan baik pada citra asli, *pan-sharpening* IHS, *Brovey*, ataupun *Gram-schmidt* kecuali kelas hutan pada *pan-sharpening* *Brovey*. Namun jika diperhatikan lebih lanjut, dapat dilihat bahwa pada citra asli dan ketiga *pan-sharpening* memiliki pola. Kelas perkebunan kopi memiliki nilai yang lebih rendah daripada kelas perkebunan non-kopi ataupun hutan pada indeks vegetasi dan nilai yang lebih tinggi pada NDBI dan NDWI. Dengan menggabungkan informasi ini, mesin mungkin akan mampu membedakan antara kelas tersebut. Dengan begitu, bila nilai indeks suatu piksel berada pada level yang sama untuk kelas perkebunan kopi, perkebunan nonkopi, dan hutan, serta nilai yang paling rendah pada indeks vegetasi, yaitu NDVI, EVI-2, dan ARVI tetapi lebih tinggi pada NDBI dan NDWI maka kemungkinan besar piksel tersebut mewakili perkebunan kopi.

B. Identifikasi Model Terbaik Deteksi Lahan Perkebunan Kopi

Berikut performa dari model *machine learning* dan model *deep learning* yang digunakan, serta perbandingannya dapat dilihat pada tabel III dan tabel IV. Tabel tersebut menunjukkan hasil *stratified 5-fold cross validation* pada *machine learning* yang sudah dilakukan *hyperparameter tuning* menggunakan *grid search*.

TABEL III
PERBANDINGAN PERFORMA MODEL MACHINE LEARNING MENGGUNAKAN STRATIFIED 5-FOLD CROSS VALIDATION.

Data	Algoritma	Akurasi	Pesisi	Recall	F1-score
Asli	SVM	80,35%	80,53%	80,35%	80,38%
	Random Forest	79,78%	80,05%	79,78%	79,82%
	XGBoost	78,56%	78,77%	78,56%	78,58%
IHS	SVM	82,98%	83,42 %	82,98 %	83,05%
	Random Forest	82,40%	82,78%	82,40%	82,48%
	XGBoost	82,88%	83,16%	82,88%	82,93%
Brovey	SVM	83,49%	83,98 %	83,49 %	83,59%
	Random Forest	82,53%	82,97%	82,53%	82,63%
	XGBoost	83,17%	83,37%	83,17%	83,18%
Gram-Schmidt	SVM	80,10%	80,77 %	80,10 %	80,16%
	Random Forest	80,99%	81,46%	80,99%	81,13%
	XGBoost	80,96%	81,32%	80,96%	81,07%

Berdasarkan tabel III, hasil *machine learning* pada citra asli menunjukkan algoritma SVM mendapatkan persentase tertinggi pada setiap aspek dimana memiliki akurasi sebesar 80,35 persen, presisi sebesar 80,53 persen; *recall* sebesar 80,35 persen; dan F1-score sebesar 80,38 persen. Sedangkan pada Pan-sharpening IHS menunjukkan bahwa algoritma SVM mendapatkan persentase tertinggi di seluruh aspek penilaian, yaitu nilai akurasi sebesar 82,98 persen presisi sebesar 83,42 persen; *recall* sebesar 82,98 persen; dan F1-score sebesar 83,05 persen. Sementara itu, pada Pan-sharpening *Brovey* diperoleh juga algoritma SVM dengan persentase tertinggi, yaitu nilai akurasi sebesar 83,49 persen; presisi sebesar 83,98 persen; *recall* sebesar 83,49 persen; dan F1-score sebesar 83,59 persen. Sedangkan pada Pan-sharpening *Gram-schmidt* algoritma *Random Forest* dengan persentase tertinggi, yaitu nilai akurasi sebesar 80,99 persen; presisi sebesar 81,46 persen; *recall* sebesar 80,99 persen; dan F1-score sebesar 81,13 persen.

Algoritma *Random forest* mendapat persentase terendah ditinjau dari nilai akurasi dan F1-score pada citra asli maupun *Pan-sharpening*, kecuali pada *Gram-Schmidt*. Persentase akurasi sebesar 80,67 persen dan F1-score sebesar 80,79 persen pada IHS, sedangkan pada *Brovey* persentase akurasi sebesar 81,56 persen dan F1-score sebesar 81,67 persen. Sebagian besar algoritma menunjukkan hasil performa lebih baik pada penggunaan data Pan-sharpening IHS daripada data Pan-sharpening *Brovey*, ataupun *Gram-Schmidt*. Hasil juga menunjukkan bahwa performa Pan-sharpening *Gram-schmidt* memiliki hasil paling buruk dibandingkan dua metode pan-sharpening lainnya, tetapi masih lebih bagus dari citra aslinya. Hal yang bisa menyebabkan perbedaan performa algoritma adalah resolusi

yang dimiliki pada Setiap proses masing-masing Pan-sharpening, artinya algoritma Pan-sharpening memiliki pengaruh terhadap hasil performa model. Selain itu, juga terdapat perbedaan panjang gelombang (wavelength) yang digunakan oleh masing-masing Pan-sharpening yang juga dapat menjadi penyebab perbedaan performa. Berdasarkan hasil yang diperoleh dipilih algoritma machine learning terbaik mendeteksi lahan perkebunan kopi, yaitu SVM pada IHS, Brovey ataupun Gram-schmidt pada Landsat-8 yang kemudian akan dibandingkan dengan hasil deep learning yang juga dievaluasi menggunakan stratified 5-fold cross validation Tabel IV. Perbandingan performa model machine learning terbaik dengan deep learning menggunakan stratified 5-fold cross validation.

TABEL IV

PERBANDINGAN PERFORMA MODEL MACHINE LEARNING MENGGUNAKAN STRATIFIED 5-FOLD CROSS VALIDATION.

Data	Algoritma	Akurasi	Presisi	Recall	F1-score
Asli	SVM	80,35%	80,53%	80,35%	80,38%
	MLP	79,14%	80,90%	77,41%	79,11%
	CNN	77,83%	78,97%	75,90%	81,40%
IHS	SVM	82,98%	83,42 %	82,98 %	83,05%
	MLP	81,47%	83,23%	79,78%	81,46%
	CNN	79,98%	81,73%	77,50%	79,55%
Brovey	SVM	83,49%	83,98 %	83,49 %	83,59%
	MLP	81,76%	83,37%	80,00%	81,65%
	CNN	79,84%	81,72%	77,21%	79,40%
Gram-Schmidt	Random Forest	80,99%	81,46%	80,99%	81,13%
	MLP	82,12%	83,59%	80,16%	81,84%
	CNN	80,61%	82,76%	78,75%	80,70%

Hasil deep learning pada tabel 12 menunjukkan algoritma MLP mendapatkan persentase yang lebih tinggi daripada algoritma CNN-1D. Didapatkan persentase nilai akurasi sebesar 81,47 persen dan F1-score sebesar 81,46 persen pada IHS, dan pada Brovey mendapat persentase nilai akurasi sebesar 81,76 persen dan F1-score sebesar 81,65 persen, sedangkan pada Gram-schmidt mendapatkan persentase nilai akurasi sebesar 82,12 persen dan F1-score sebesar 81,84 persen. Kemudian algoritma CNN-1D pada IHS persentase nilai akurasi sebesar 79,98 persen dan F1-score sebesar 79,55 persen, dan pada Brovey mendapat persentase nilai akurasi sebesar 79,85 persen dan F1-score sebesar 79,40 persen, sedangkan pada Gram-schmidt mendapatkan persentase nilai akurasi sebesar 80,61 persen dan F1-score sebesar 80,70 persen. Hasil menunjukkan data Brovey mendapatkan nilai persentase yang lebih tinggi daripada data IHS dan Gram-schmidt atau dengan kata lain pengaruh resolusi spasial juga berlaku pada metode deep learning dalam menghasilkan performa model. Berdasarkan analisis deskriptif yang telah dijelaskan, maka hasil model terbaik dipilih algoritma SVM pada Brovey karena memiliki nilai tertinggi di seluruh aspek penilaian

C. Mengestimasi Luas Lahan Perkebunan Kopi Menggunakan Model Terbaik

Hasil estimasi luas lahan perkebunan kopi menggunakan model SVM pada citra satelit Landsat-8 dengan menggunakan

data hasil pan-sharpening Brovey, diperoleh luas lahan perkebunan kopi di kabupaten OKU Selatan tahun 2022 sebesar 120501,56 Ha atau lebih 30.999,56 Ha (25,72 persen) bila dibandingkan data tabel dinamis BPS provinsi Sumatera Selatan sebesar 89.260 Ha. Sementara itu, bila dibandingkan data tabel dinamis BPS Kabupaten OKU Selatan sebesar 89.050 Ha yang didapatkan melalui akumulasi luas lahan perkebunan kopi tiap kecamatan, hasil estimasi lebih luas 30,999,56 Ha (25,72 persen). Hal ini dikarenakan data lahan perkebunan kopi didapatkan bersumber dari laporan yang disediakan oleh Dinas Perkebunan sesuai level administrasi. Artinya data tabel dinamis BPS provinsi bersumber dari dinas perkebunan provinsi sedangkan data tabel dinamis BPS kabupaten bersumber dari dinas perkebunan kabupaten

TABEL V

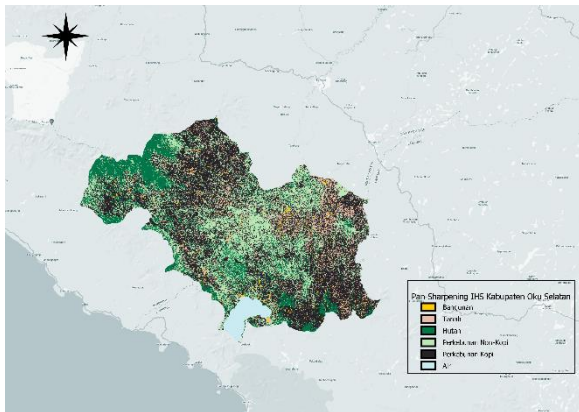
PERBANDINGAN HASIL ESTIMASI LUAS PERKEBUNAN KOPI DENGAN DATA TABEL DINAMIS BERDASARKAN KECAMATAN DI KABUPATEN OKU SELATAN TAHUN 2022

Kecamatan	Luas Lahan (Ha)	Estimasi (Ha)	Selisih (Ha)
Mekakau Ilir	9228	8921	3560,47
Banding Agung	4356	7548,38	275,87
Warkuk Ranau Selatan	5847	5629,92	82,92
BPR Ranau Tengah	9264	8366,03	218
Buay Pemaca	6640	3287,04	14920,22
Simpang	101	1907,82	5507,83
Buana Pemaca	1971	3254,43	1283,43
Buay Rawan	950	7348,36	3111,36
Buay Sandang Aji	5051	6183,71	2354,97
Tiga Dihaji	3511	3753,62	1090,97
Buay Runjung	3091	5393,71	2766,47
Runjung Agung	5871	8279,01	928,83
Kisam Tinggi	9015	19807,46	6818,86
Muaradua Kisam	6114	4837,91	2444,51
Kisam Ilir	4218	2950,29	1963,54
Pulau Beringin	6035	11636,18	6646,67
Sindang Danau	6065	5468,94	119,78
Sungai Are	2174	5927,75	3316,03
Total	89502	120501,56	30999,56

Berdasarkan tabel V, terdapat selisih yang cukup besar pada tiap kecamatan antara luas lahan perkebunan dengan estimasi luas lahan perkebunan. Hal ini dikarenakan tingkat ketelitian pada wilayah administrasi yang semakin kecil akan menimbulkan selisih yang semakin besar. Selain itu, selisih estimasi lahan perkebunan kopi juga mungkin disebabkan karena kesalahan klasifikasi model SVM terhadap kelas perkebunan non-kopi. Kemudian, juga terdapat piksel klasifikasi kelas perkebunan kopi yang tidak mengumpul sepenuhnya pada satu tempat, sehingga dapat menjadi penyebab perbedaan cukup besar atau terdapat selisih hasil estimasi dengan data official statistics.

Metode pengumpulan data yang dilakukan pada Survei Perusahaan Perkebunan (SKB) perkebunan kopi dilakukan dengan metode self-enumeration yang diisi oleh pemilik perkebunan berdasarkan hasil estimasinya masing-masing. Hal ini juga dapat menjadi penyebab kurang tepatnya laporan luas lahan dengan keadaan sesungguhnya. Berikut peta tutupan

lahan Kabupaten OKU Selatan berdasarkan hasil klasifikasi *random forest* yang ditunjukkan pada Gambar 6.



Gambar 6. Hasil klasifikasi model SVM pada citra satelit Landsat-8 metode *pan-sharpening Brovey*

VII. PENUTUP

A. Kesimpulan

Penelitian ini mampu mendeteksi lahan perkebunan kopi termasuk wilayah yang sulit dijangkau atau menurut batas wilayah penelitian. Berdasarkan hasil dan pembahasan yang dijelaskan sebelumnya, beberapa hal yang dapat disimpulkan.

- 1) Untuk mengetahui efek dari berbagai metode *pan-sharpening* dalam mendeteksi lahan perkebunan kopi pada citra satelit Landsat-8, penelitian ini menganalisis perbedaan nilai indeks vegetasi (NDVI, EVI, dan ARVI). Hasil menunjukkan bahwa lahan perkebunan kopi cenderung memiliki nilai indeks vegetasi yang lebih rendah, tetapi memiliki nilai yang lebih tinggi pada NDBI dan NDWI dibandingkan dengan kelas perkebunan non-kopi atau hutan.
- 2) Untuk mendapat model klasifikasi terbaik dalam mendeteksi lahan perkebunan kopi, penelitian ini berhasil menghasilkan model SVM pada data *Brovey* yang menunjukkan performa unggul. Hal ini ditunjukkan dari performa nilai akurasi, presisi, *recall*, dan *F1-score* yang tertinggi, yaitu akurasi sebesar 83,49 persen dan *F1-score* sebesar 83,59 persen
- 3) Untuk mengestimasi luas lahan perkebunan kopi menggunakan model terbaik SVM, didapatkan hasil estimasi luas perkebunan kopi di kabupaten OKU Selatan tahun 2022 seluas 120.501,67 Ha pada data citra Landsat-8 hasil *pan-sharpening Brovey*.

B. Saran

Berdasarkan hasil dan pembahasan, terdapat beberapa saran yang dapat diajukan.

- 1) Untuk penelitian selanjutnya, melakukan *post classification processing*, karena masih banyak piksel hasil klasifikasi tutupan lahan yang tidak sesuai pada kelas

yang seharusnya. Misalnya terdapat piksel hutan di tengah-tengah perkebunan nonkopi atau bayangan awan yang terklasifikasi menjadi piksel perkebunan kopi.

- 2) Untuk pengembangan lebih lanjut dari penelitian ini, fokuskan penelitian pada pengembangan atau perbaikan metode *pan-sharpening*. Hal ini karena proses *pan-sharpening* sering kali mengorbankan informasi spektral untuk meningkatkan resolusi spasial. Ini dapat mengakibatkan penurunan dalam kemampuan untuk membedakan antara objek atau fitur berdasarkan karakteristik spektralnya. Pengembangan ini dapat mencakup pembuatan algoritma baru atau penyesuaian parameter yang lebih baik untuk menciptakan citra gabungan yang lebih akurat dan informatif.

DAFTAR PUSTAKA

- [1] Coffee Shops - Global Strategic Business Report" [Online]. Available: <https://finance.yahoo.com/news/global-coffee-shops-strategic-business-085800157.html?>. Diakses 09 November 2023.
- [2] "Coffee : World Markets and Trade" [Online]. Available: <https://apps.fas.usda.gov/psdonline/circulars/coffee.pdf>.
- [3] Y. Nurhanisah. (2023). Provinsi Penghasil Kopi Terbesar. <https://indonesiabaik.id/infografis/provinsi-penghasil-kopi-terbesar>. Diakses 09 November 2023
- [4] Direktorat Statistik Tanaman, Pangan Hortikultura, and Perkebunan, Statistik Kopi Indonesia 2021: Badan Pusat Statistik, 2022.
- [5] D. W. Trisowati and A. W. Wijayanto, "Peluang dan tantangan dalam pemanfaatan teknologi penginderaan jauh dan machine learning untuk prediksi data tanaman pangan yang lebih akurat," in Seminar Nasional Official Statistics, 2019, pp. 177-187..
- [6] Aziz, M. "Pemanfaatan Citra Sentinel-2A untuk Estimasi Produksi Tanaman Kopi di Sebagian Wilayah Kabupaten Temanggung", 2019.
- [7] H. Dibs, H. Ali Hasab, A. S. Mahmoud, N. Al-Ansari, "Fusion Methods and Multi-classifiers to Improve Land Cover Estimation Using Remote Sensing Analysis", Geotechnical and Geological Engineering, vol. 39, p. 5825, 2021.
- [8] N. Yusof, H. Z. M. Shafri, and N. S. N. Shaharum, "The use of Landsat-8 and Sentinel-2 imageries in detecting and mapping rubber trees," Journal of Rubber Research, vol. 24, pp. 121-135, 2021
- [9] J. Jagannathan, C. Divya, "Deep learning for the prediction and classification of land use and land cover changes using deep convolutional neural network", IEEE, vol. 8, 2020.
- [10] Damayanti, A. M. Liyantono, "Identifikasi Tanaman Kopi (Coffea) di Provinsi Jawa Barat berbasis Machine Learning SVM dan Random Forest Citra Satelit Landsat-8", 2021.
- [11] Badan Pusat Statistik. (2021-2022). Luas Tanaman Perkebunan (Hektare). <https://sumsel.bps.go.id/indikator/54/414/1/luas-tanaman-perkebunan.html>. Diakses 09 November 2023
- [12] N. Yusof, H. Z. M. Shafri, and N. S. N. Shaharum, "The use of Landsat-8 and Sentinel-2 imageries in detecting and mapping rubber trees," Journal of Rubber Research, vol. 24, pp. 121-135, 2021
- [13] C. Haub, L. Kleinewillinghöfer, V. Garcia Millan (EFTAS), and A. Di Gregorio (FAO), "Protocol For Land Cover Validation," SIGMA – Stimulating Innovation for Global Monitoring of Agriculture, 2015..
- [14] Carper, W. J., Lillesand, T. M., & Kiefer, R. W. (1990). The use of intensity-hue-saturation transformations for merging SPOT panchromatic and multispectral image data. *Photogrammetric Engineering and Remote Sensing*, 56(4), 459-467.
- [15] Chavez, P. S., Jr., Sides, S. C., & Anderson, J. A. (1991). Comparison of three different methods to merge multiresolution and multispectral data: Landsat TM and SPOT panchromatic. *Photogrammetric Engineering and Remote Sensing*, 57(3), 295-303.
- [16] Aiazzi, B., Baronti, S., Selva, M., & Alparone, L. (2007). Advantages of the Gram-Schmidt spectral sharpening of multispectral image data. *Remote Sensing of Environment*, 107(1-2), 164-172.
- [17] Sitanggang, G., Carolita I., B.H. Trisasonko. "Aplikasi Teknik dan Metode Fusi Data Optik ETM-Plus Landsat dan Sar Radarsat untuk

- Ekstraksi Informasi Geologi Pertambangan Batu Bara". Lapan. Vol. 6, 2004
- [18] Wandayani, A, "Perbandingan Metode Brovey dan PCA dalam Fusi Citra Panchromatic dan Multispectral. Laporan Tugas Akhir. Departemen Ilmu Komputer Fakultas Matematika dan Ilmu Pengetahuan Alam Institut Pertanian Bogor", 2007
- [19] Daenodoro, Projo, "Pengantar Penginderaan Jauh Digital.", 2012
- [20] USGS. Landsat 8 Band Designations. <https://www.usgs.gov/media/images/landsat-8-band-designations>. Diakses 8 Maret 2022.
- [21] T. Hoeser, F. Bachofer, and C. Kuenzer, "Object detection and image segmentation with deep learning on Earth observation data: A review—Part II: Applications," *Remote Sensing*, vol. 12, p. 3053, 2020.
- [22] F. G. S. Bezerra, A. P. D. Aguiar, R. C. d. S. Alvalá, A. Giarolla, K. R. A. Bezerra, P. V. P. S. Lima, et al., "Analysis of areas undergoing desertification, using EVI2 multi-temporal data based on MODIS imagery as indicator," *Ecological Indicators*, vol. 117, p. 106579, 2020.
- [23] T. Lillesand, R. W. Kiefer, and J. Chipman, *Remote sensing and image interpretation*: John Wiley & Sons, 2015.
- [24] G. Rondeaux, M. Steven, and F. Baret, "Optimization of soil-adjusted vegetation indices," *Remote sensing of environment*, vol. 55, pp. 95-107, 1996.
- [25] Z. Jiang, A. R. Huete, K. Didan, and T. Miura, "Development of a two-band enhanced vegetation index without a blue band," *Remote sensing of Environment*, vol. 112, pp. 3833-3845, 2008.
- [26] I. N. Hidayati, R. Suharyadi, and P. Danoedoro, "Developing an extraction method of urban built-up area based on remote sensing imagery transformation index," in *Forum Geografi*, 2018, pp. 96-108.
- [27] V. K. Gautam, P. K. Gaurav, P. Murugan, and M. Annadurai, "Assessment of surface water Dynamics in Bangalore using WRI, NDWI, MNDWI, supervised classification and KT transformation," *Aquatic Procedia*, vol. 4, pp. 739-746, 2015.
- [28] N. Verde, I. P. Kokkoris, C. Georgiadis, D. Kaimaris, P. Dimopoulos, I. Mitsopoulos, et al., "National scale land cover classification for ecosystem services mapping and assessment, using multitemporal copernicus EO data and google earth engine," *Remote Sensing*, vol. 12, p. 3303, 2020.
- [29] Y. Chen, P. Dou, and X. Yang, "Improving land use/cover classification with a multiple classifier system using AdaBoost integration technique," *Remote Sensing*, vol. 9, p. 1055, 2017.
- [30] L. Breiman, "Random forests," *Machine learning*, vol. 45, pp. 5-32, 2001.
- [31] D. W. Triscowati, B. Sartono, A. Kurnia, D. D. Domiri, and A. W. Wijayanto, "Multitemporal remote sensing data for classification of food crops plant phase using supervised random forest," in *Sixth Geoinformation Science Symposium*, 2019, p. 1131102.
- [32] K. Budholiya, S. K. Shrivastava, and V. Sharma, "An optimized XGBoost based diagnostic system for effective prediction of heart disease," *Journal of King Saud University-Computer and Information Sciences*, 2020.
- [33] M. S. T. Putra and Y. Azhar, "Perbandingan Model Logistic Regression dan Artificial Neural Network pada Prediksi Pembatalan Hotel," *JISKA (Jurnal Informatika Sunan Kalijaga)*, vol. 6, pp. 29-37, 2021.
- [34] W. Jiang, G. He, T. Long, Y. Ni, H. Liu, Y. Peng, et al., "Multilayer perceptron neural network for surface water extraction in Landsat 8 OLI satellite images," *Remote Sensing*, vol. 10, p. 755, 2018.
- [35] F. Hu, G.-S. Xia, J. Hu, and L. Zhang, "Transferring deep convolutional neural networks for the scene classification of high-resolution remote sensing imagery," *Remote Sensing*, vol. 7, pp. 14680-14707, 2015.
- [36] A. Peryanto, A. Yudhana, and R. Umar, "Klasifikasi Citra Menggunakan Convolutional Neural Network dan K Fold Cross Validation," *Journal of Applied Informatics and computing*, vol. 4, pp. 45-51, 2020.
- [37] M. Berndtsson, J. Hansson, B. Olsson, and B. Lundell, *Thesis projects: a guide for students in computer science and information systems*: Springer Science & Business Media, 2007.